Desarrollo_TP1

April 16, 2018

```
In [1]: %matplotlib inline
        import datetime as datetime
        import pandas as pd
        import numpy as np
        import matplotlib.pyplot as plt
        import seaborn as sns
```

1 Desarrollo

2 Sets de datos

Nos dieron 6 archivos .csv con datos para analizar:

- postulantes_educacion = ‘fiuba_1_postulantes_educacion.csv'

- postulantes_genero_edad = ‘fiuba_2_postulantes_genero_y_edad.csv'

- vistas = 'fiuba_3_vistas.csv'

- postulaciones = 'fiuba_4_postulaciones.csv'

- avisos_online = 'fiuba_5_avisos_online.csv'

- avisos_detalles = 'fiuba_6_avisos_detalle.csv'

2.0.1 Analizamos el set de datos: ‘postulantes_educacion’

```
In [2]: postulantes_educacion = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/
```

Vemos que forma tienen los datos

```
In [3]: postulantes_educacion.head()
```

Out[3]:

	idpostulante	nombre	estado
0	NdJl	Posgrado	En Curso
1	8BkL	Universitario	En Curso
2	1d2B	Universitario	En Curso
3	NPBx	Universitario	En Curso
4	NPBx	Master	En Curso

```
In [4]: postulantes_educacion.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 298231 entries, 0 to 298230
Data columns (total 3 columns):
idpostulante    298231 non-null object
nombre          298231 non-null object
estado          298231 non-null object
dtypes: object(3)
memory usage: 6.8+ MB
```

Vemos que es un set de datos completo, es decir que no tiene valores nulos en ninguna de sus columnas.

Comprobamos que no haya ids repetidos:

```
In [4]: postulantes_educacion['idpostulante'].value_counts().head()

Out[4]: YlMLGD     9
        54MQGz     8
        EZD29      8
        EzOLBk9    7
        8M21pBL    7
        Name: idpostulante, dtype: int64
```

Vemos que si los hay, por lo que vamos a filtarlos quedandonos que el nivel educativo superior de cada postulante

Vamos a analizar el nivel educativo de los postulantes.

Qusimos ver la distribucion del nivel educativo de los estudiantes, por lo que utilizamos la columna nombre

```
In [5]: postulantes_educacion['nombre'].value_counts()

Out[5]: Secundario           110256
        Universitario        104295
        Terciario/Técnico     47733
        Otro                  24748
        Posgrado               7387
        Master                 3598
        Doctorado               214
        Name: nombre, dtype: int64
```

En este caso hay categorías con tildes, la cual despues traen complicaciones a la hora de graficar con matplotlib que no las soporta, por lo que vamos a cambiarle el nombre.

```
In [6]: postulantes_educacion['nombre'] = postulantes_educacion['nombre'].astype('string')

In [7]: import unicodedata
        def elimina_tildes(s):
           return ''.join((c for c in unicodedata.normalize('NFD', s) if unicodedata.category(c)
```

```
In [8]: postulantes_educacion['nombre'] = postulantes_educacion['nombre'].apply(lambda x: elimin
```

Nos dimos cuenta de que el nivel educativo no depende solo de la columna nombre, sino que tambien depende del estado.

```
In [9]: postulantes_educacion['estado'].value_counts()

Out[9]: Graduado      194474
        En Curso       78531
        Abandonado     25226
        Name: estado, dtype: int64
```

Por lo tanto quisimos crear una columna categórica que incluya a ambos campos

```
In [10]: postulantes_educacion['nombre-estado'] = postulantes_educacion['nombre'] + ' - ' + post

In [11]: postulantes_educacion['nombre-estado'] = postulantes_educacion['nombre-estado'].astype(

In [12]: postulantes_educacion.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 298231 entries, 0 to 298230
Data columns (total 4 columns):
idpostulante     298231 non-null object
nombre           298231 non-null object
estado           298231 non-null object
nombre-estado    298231 non-null category
dtypes: category(1), object(3)
memory usage: 7.1+ MB
```

Ahora queremos que estas categorías tengasn un orden, para que un doctorado sea mayor a un secundario

```
In [13]: categories_order = ['Otro - Abandonado',
          'Otro - En Curso',
          'Otro - Graduado',
         'Secundario - Abandonado',
          'Secundario - En Curso',
          'Secundario - Graduado',
          'Terciario/Tecnico - Abandonado',
          'Terciario/Tecnico - En Curso',
          'Terciario/Tecnico - Graduado',
          'Universitario - Abandonado',
          'Universitario - En Curso',
          'Universitario - Graduado',
         'Posgrado - Abandonado',
          'Posgrado - En Curso',
          'Posgrado - Graduado',
```

```
          'Master - Abandonado',
          'Master - En Curso',
          'Master - Graduado',
         'Doctorado - Abandonado',
          'Doctorado - En Curso',
          'Doctorado - Graduado']
```

```
In [14]: postulantes_educacion['nombre-estado'] = postulantes_educacion['nombre-estado'].cat \
                                                  .set_categories(categories_order, ordered = Tru
```

Finalmente nos quedamos con el mayor grado de cada uno.

```
In [15]: postulantes_educacion = postulantes_educacion.sort_values('nombre-estado', ascending= F
```

```
In [16]: postulantes_educacion['nombre-estado'].value_counts().sort_index()
```

```
Out[16]: Otro - Abandonado                  219
         Otro - En Curso                    186
         Otro - Graduado                    933
         Secundario - Abandonado           2681
         Secundario - En Curso             3397
         Secundario - Graduado            56333
         Terciario/Tecnico - Abandonado    3034
         Terciario/Tecnico - En Curso      9730
         Terciario/Tecnico - Graduado     14665
         Universitario - Abandonado        9895
         Universitario - En Curso         46685
         Universitario - Graduado         31258
         Posgrado - Abandonado              248
         Posgrado - En Curso               1730
         Posgrado - Graduado               4072
         Master - Abandonado                131
         Master - En Curso                 1449
         Master - Graduado                 1895
         Doctorado - Abandonado              15
         Doctorado - En Curso                91
         Doctorado - Graduado               105
         Name: nombre-estado, dtype: int64
```

Vemos que funciono el ordenamiento
Comprobamos que ya no tenemos duplicados

```
In [17]: postulantes_educacion['idpostulante'].value_counts().head()
```

```
Out[17]: Rz6VOrE    1
         bOJLX14    1
         96XOwba    1
         1QrA4ez    1
         5avONz     1
         Name: idpostulante, dtype: int64
```

Ahora, con los datos filtrados, nos fijamos cómo quedó la distrubucion de estados

```
In [18]: postulantes_educacion['estado'].value_counts()
```

```
Out[18]: Graduado      109261
         En Curso       63268
         Abandonado     16223
         Name: estado, dtype: int64
```

Lo graficamos así se ve mejor

```
In [34]: fig, ax = plt.subplots()
         ax.bar(np.arange(3), postulantes_educacion['estado'].value_counts(), color = ['#00ff00'
         ax.set_ylabel('Cantidad de postulantes')
         ax.set_xlabel('Estado de educacion')
         ax.set_xticks(np.arange(3))
         ax.set_xticklabels( postulantes_educacion['estado'].value_counts().index, rotation=0)
         ax.set_title('Cantidad de postulantes por estado', size = 15)
```

```
Out[34]: <matplotlib.text.Text at 0x7f77dfb57710>
```

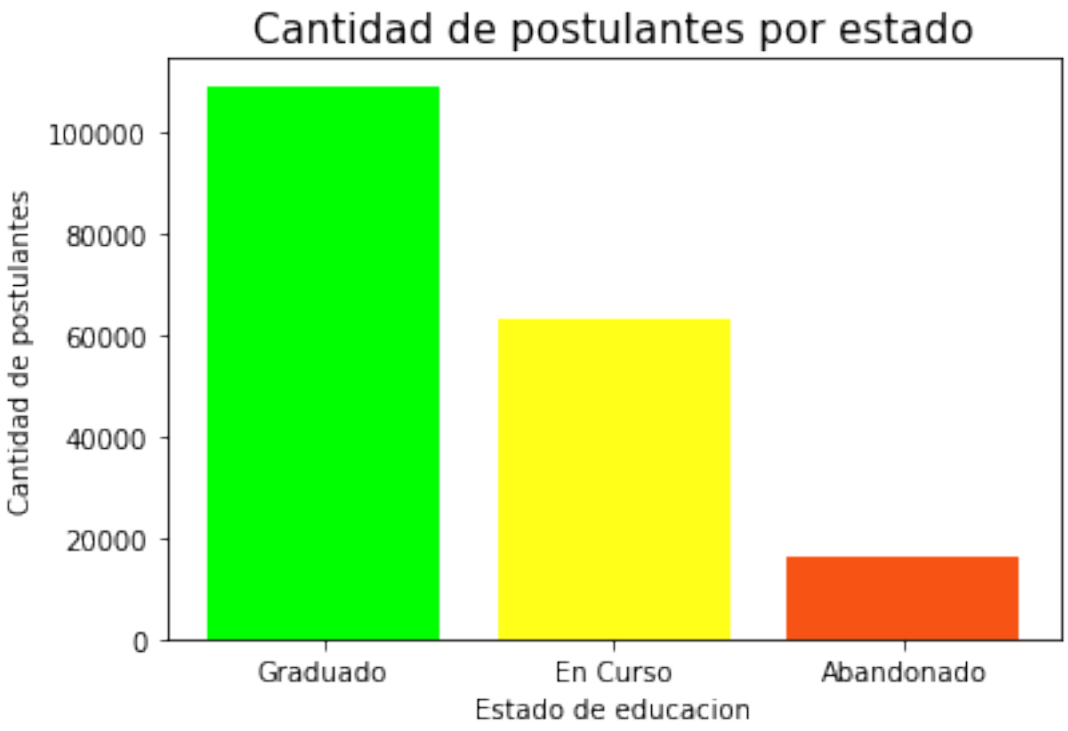

Agrupamos para ver mejor la informacion

```
In [36]: postulantes_nombre = postulantes_educacion.groupby(['estado', 'nombre'])['idpostulante'
         postulantes_nombre
```

```
Out[36]: estado      nombre
         Abandonado  Doctorado               15
                     Master                 131
                     Otro                   219
                     Posgrado               248
                     Secundario            2681
                     Terciario/Tecnico     3034
                     Universitario         9895
         En Curso    Doctorado               91
                     Master                1449
                     Otro                   186
                     Posgrado              1730
                     Secundario            3397
                     Terciario/Tecnico     9730
                     Universitario        46685
         Graduado    Doctorado              105
                     Master                1895
                     Otro                   933
                     Posgrado              4072
                     Secundario           56333
                     Terciario/Tecnico    14665
                     Universitario        31258
         Name: idpostulante, dtype: int64
```

Hago un gráfico de los estados, ahora por tipo de educación para que se pueda apreciar mejor.

```
In [43]: estados = postulantes_educacion['estado'].value_counts().index
         nombres = ['Otro', 'Secundario','Terciario/Tecnico','Universitario','Posgrado','Master'

         width = 0.35
         for nombre in nombres:
             postulantes_estado = []
             fig, ax = plt.subplots()
             for estado in estados:
                 postulantes_estado.append(postulantes_nombre[estado][nombre])
             ax.bar(np.arange(3), postulantes_estado, color = ['#00ff00', '#ffff1a','#f65314'])
             ax.set_ylabel('Cantidad de postulantes')
             ax.set_xlabel('Estado de educacion')
             ax.set_xticks(np.arange(3))
             ax.set_xticklabels(estados,rotation=0)
             ax.set_title('Cantidad de postulantes con educacion de tipo: \n"' + nombre + '" por
```

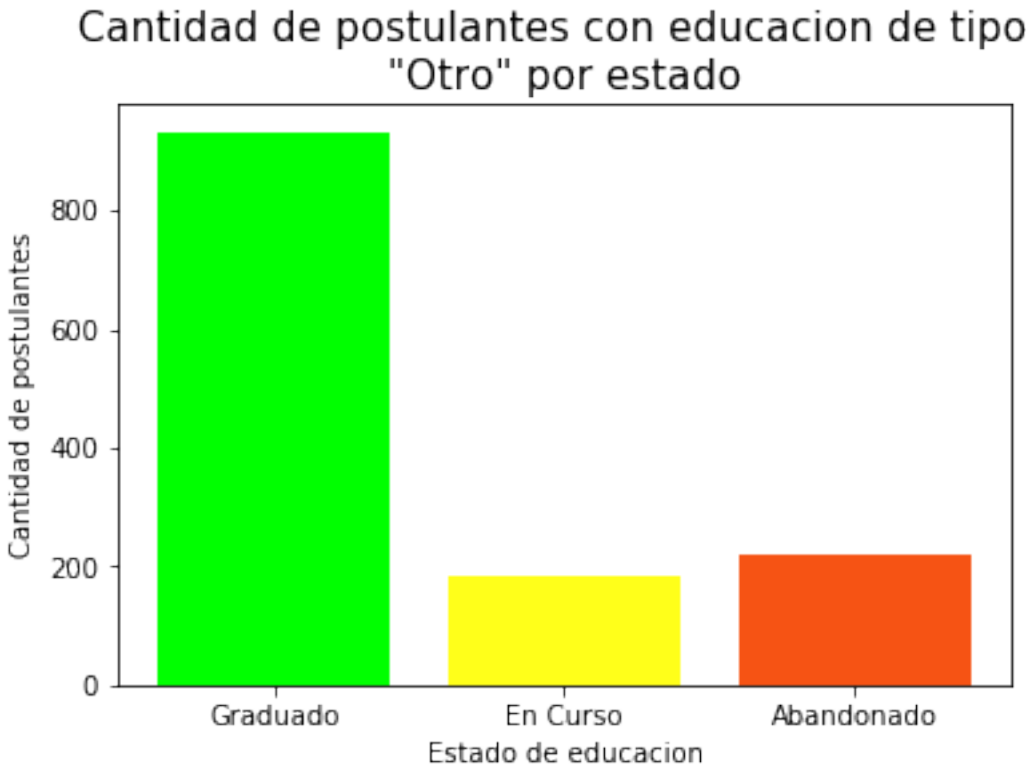
Cantidad de postulantes con educacion de tipo:
"Otro" por estado
Cantidad de postulantes
0
200
400
600
800
Graduado
En Curso
Abandonado
Estado de educacion

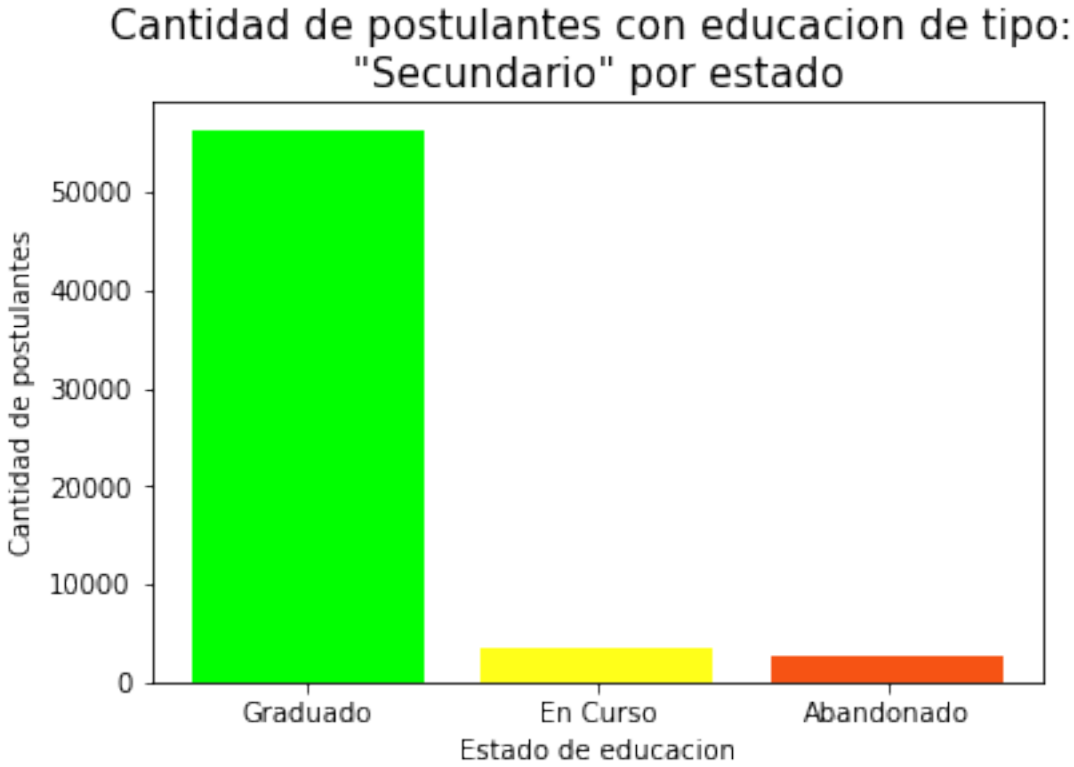
Cantidad de postulantes con educacion de tipo:
"Secundario" por estado
Cantidad de postulantes
0
10000
20000
30000
40000
50000
Graduado
En Curso
Abandonado
Estado de educacion

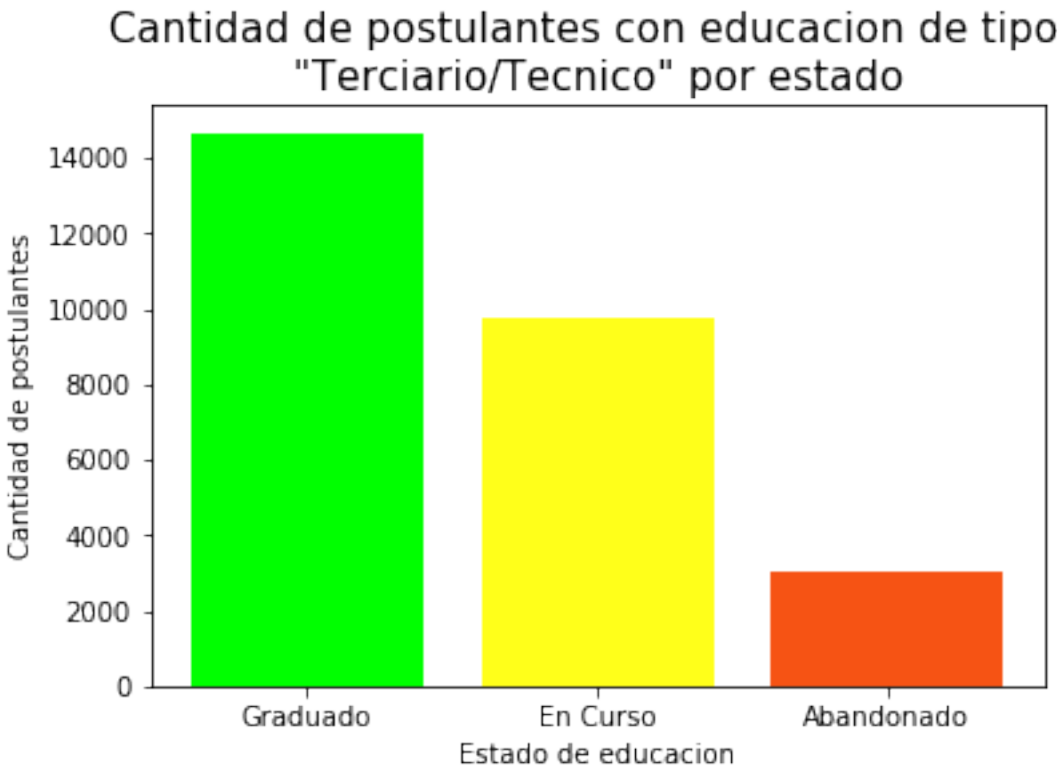
Cantidad de postulantes con educacion de tipo:
"Terciario/Tecnico" por estado
Cantidad de postulantes
14000
12000
10000
8000
6000
4000
2000
0
Graduado
En Curso
Abandonado
Estado de educacion

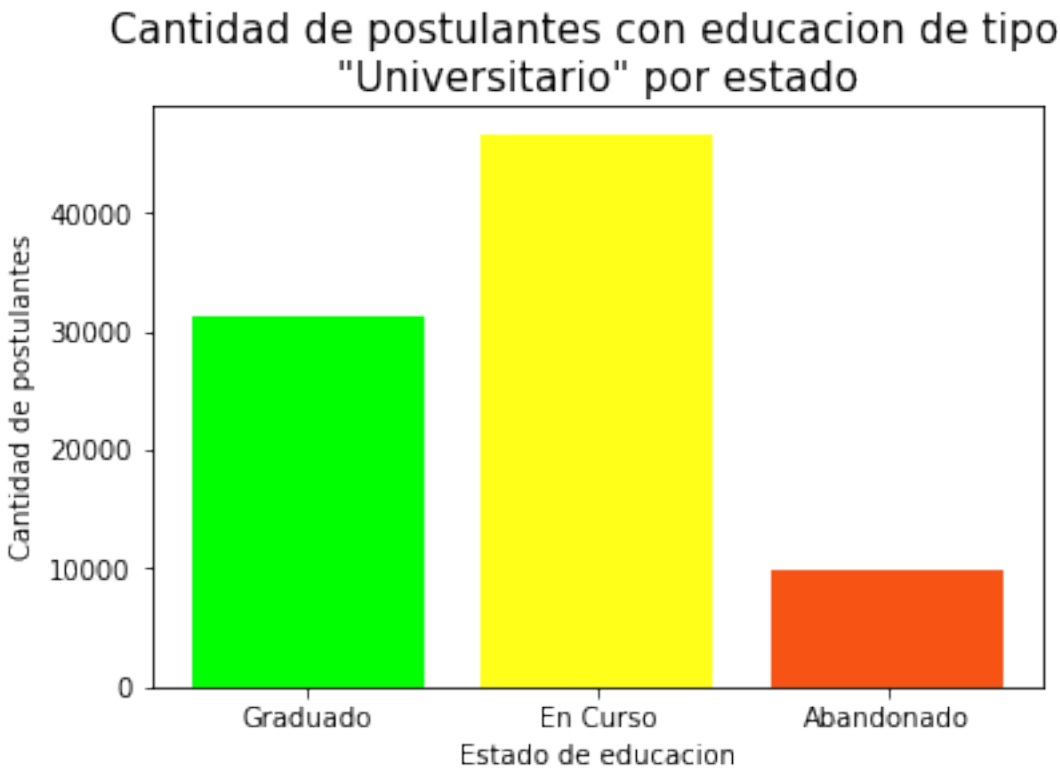
Cantidad de postulantes con educacion de tipo:
"Universitario" por estado
Cantidad de postulantes
40000
30000
20000
10000
0
Graduado
En Curso
Abandonado
Estado de educacion

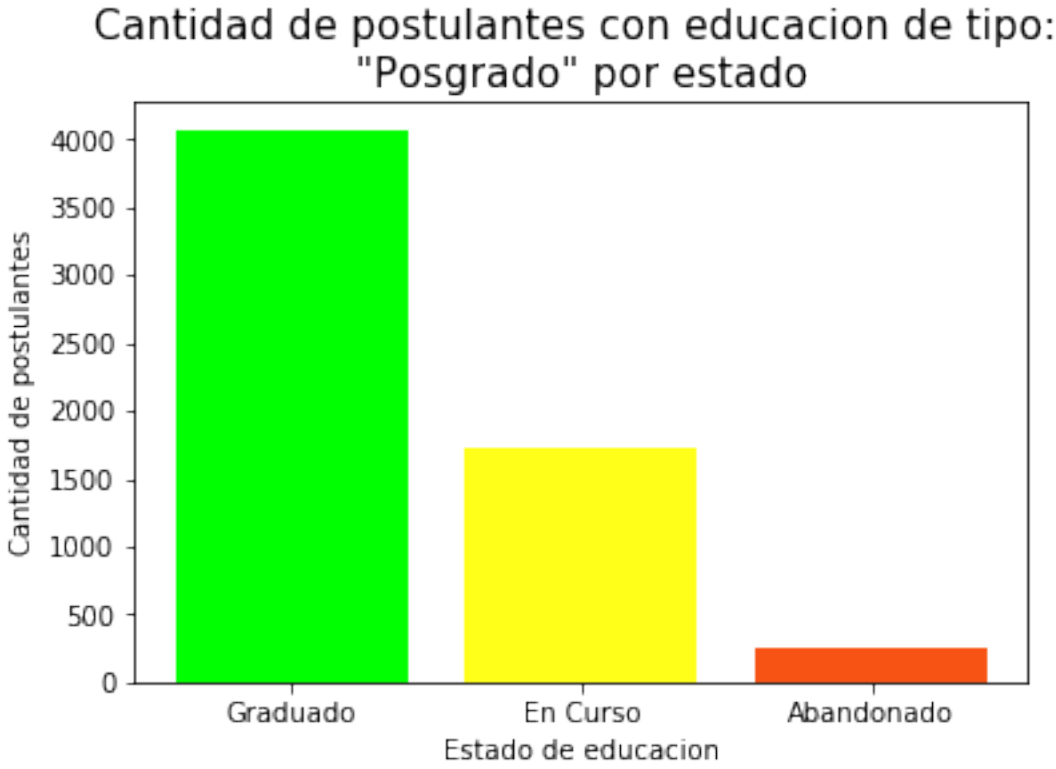
Cantidad de postulantes con educacion de tipo:
"Posgrado" por estado
Cantidad de postulantes
4000
3500
3000
2500
2000
1500
1000
500
0
Graduado
En Curso
Abandonado
Estado de educacion

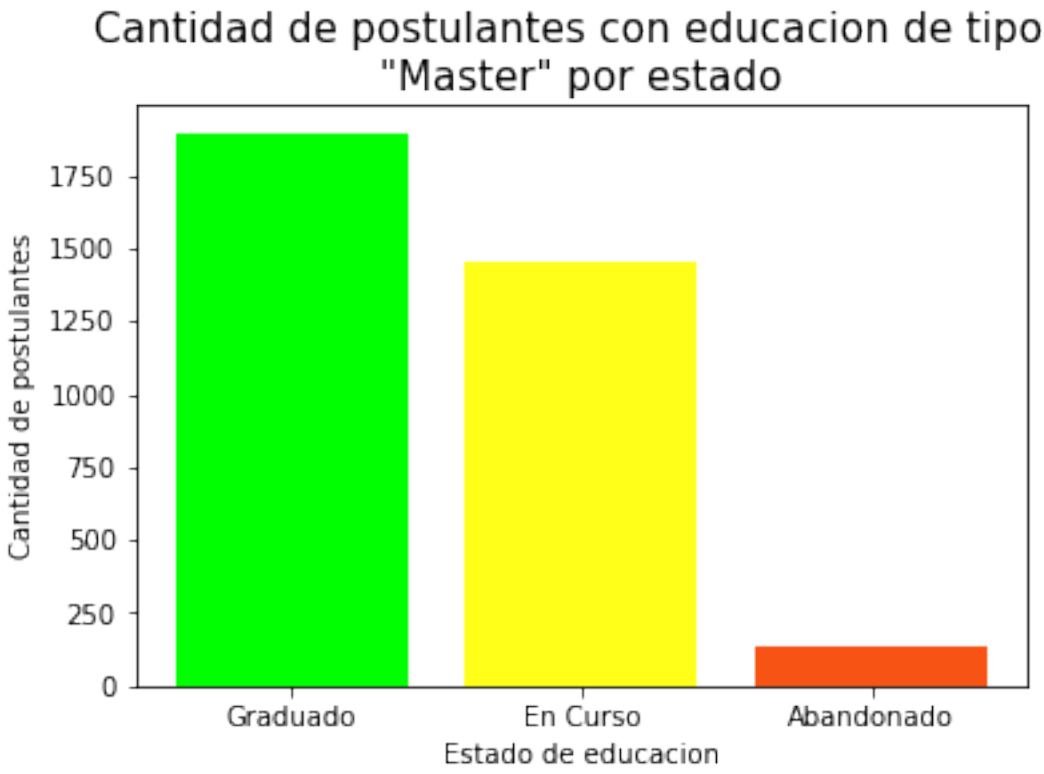
Cantidad de postulantes con educacion de tipo:
"Master" por estado
Cantidad de postulantes
1750
1500
1250
1000
750
500
250
0
Graduado
En Curso
Abandonado
Estado de educacion

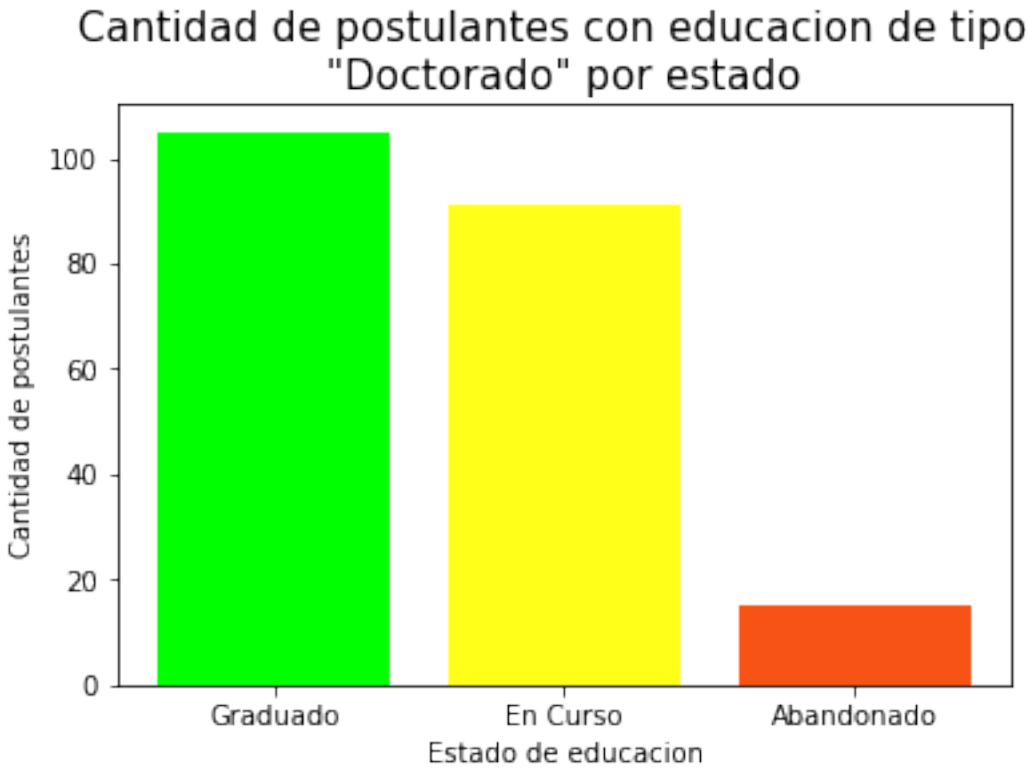

Vemos que en la mayoría de las categorías las personas ponen, en su mayoría el nivel graduado, con exceptcion de los estudiantes universitarios, donde la mayoría se encuantra "En Curso".

Son en general pocos, en todos los casos los que usan la categoría abandonado

Ahora hacemos al revés, y para cada estado dibujamos la cantidad de estudiantes en cada tipo de institucion

```
In [45]: def get_color(unEstado):
             if estado == 'Abandonado': return '#f65314'
             if estado == 'En Curso': return '#ffff1a'
             if estado == 'Graduado': return '#00ff00'

         width = 0.35
         for estado in estados:
             postulantes_estado = []
             fig, ax = plt.subplots()
             for nombre in nombres:
                 postulantes_estado.append(postulantes_nombre[estado][nombre])
             ax.bar(np.arange(len(nombres)), postulantes_estado, color = get_color(estado))
             ax.set_xticks(np.arange(len(nombres)))
             ax.set_xticklabels(nombres,rotation=50)
             ax.set_ylabel('Cantidad de postulantes')
             ax.set_xlabel('Tipo de educacion')
```

```
ax.set_title('Cantidad de postulantes con educacion en estado: "' + estado + '"', s
```

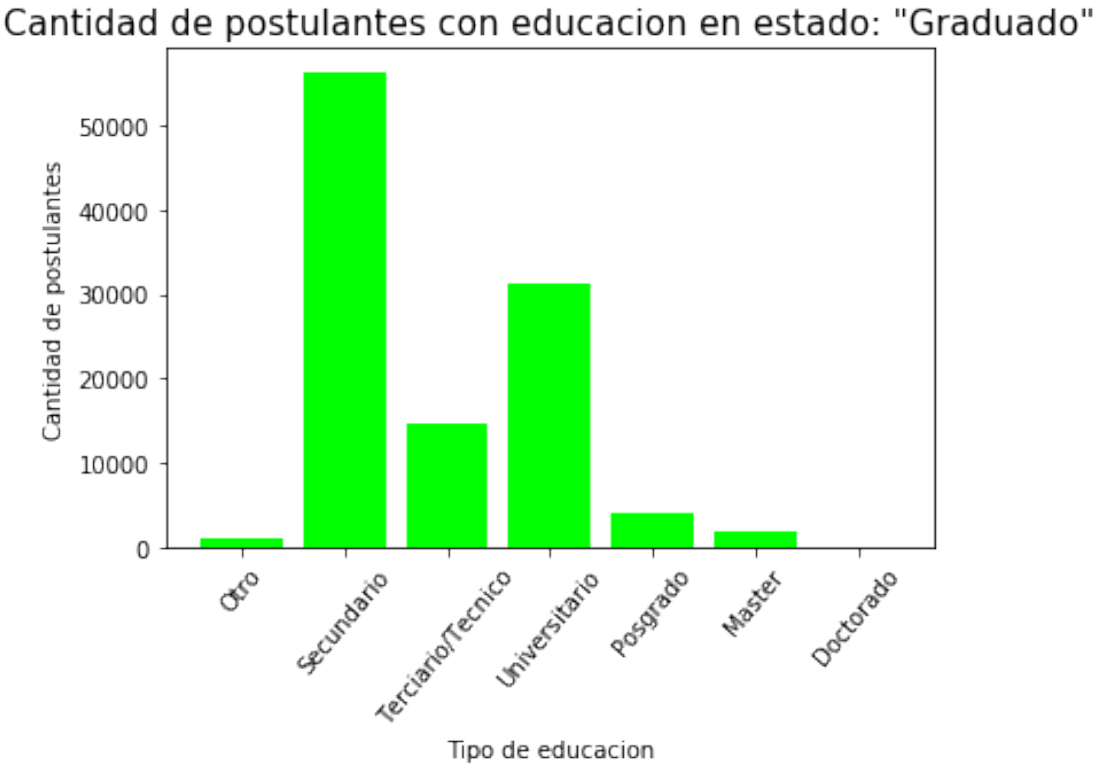

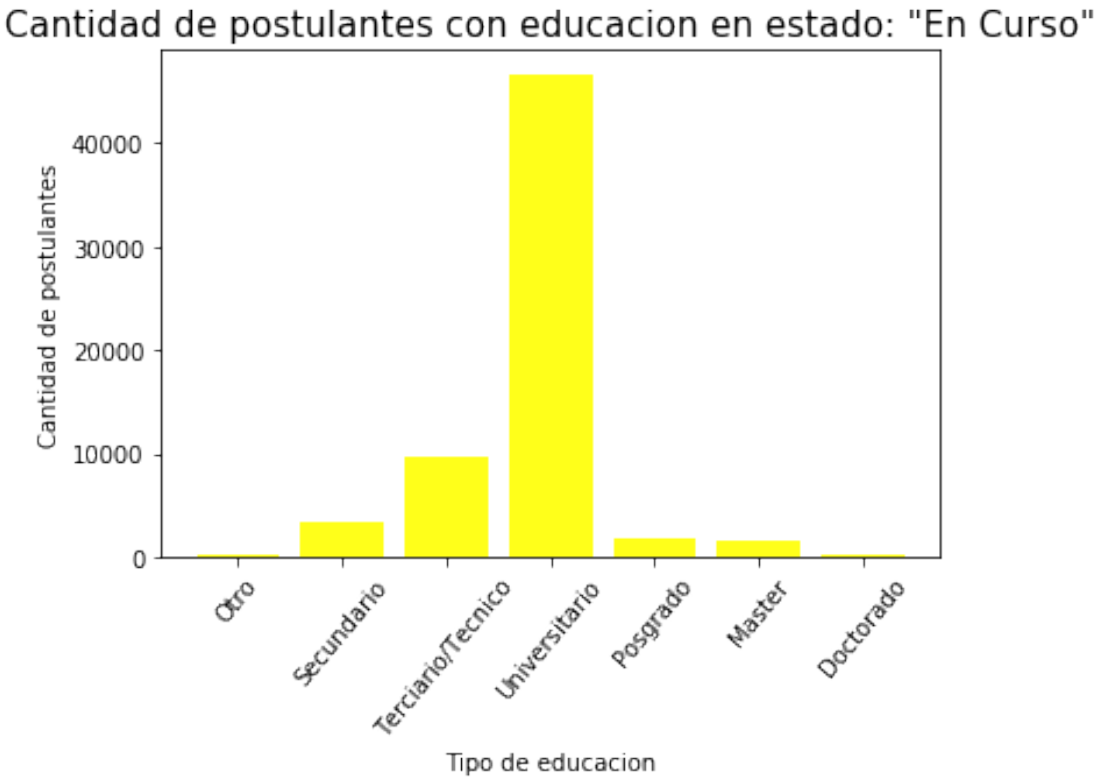
Cantidad de postulantes con educacion en estado: "En Curso"
Cantidad de postulantes
40000
30000
20000
10000
0
Otro
Secundario
Terciario/Tecnico
Universitario
Posgrado
Master
Doctorado
Tipo de educacion

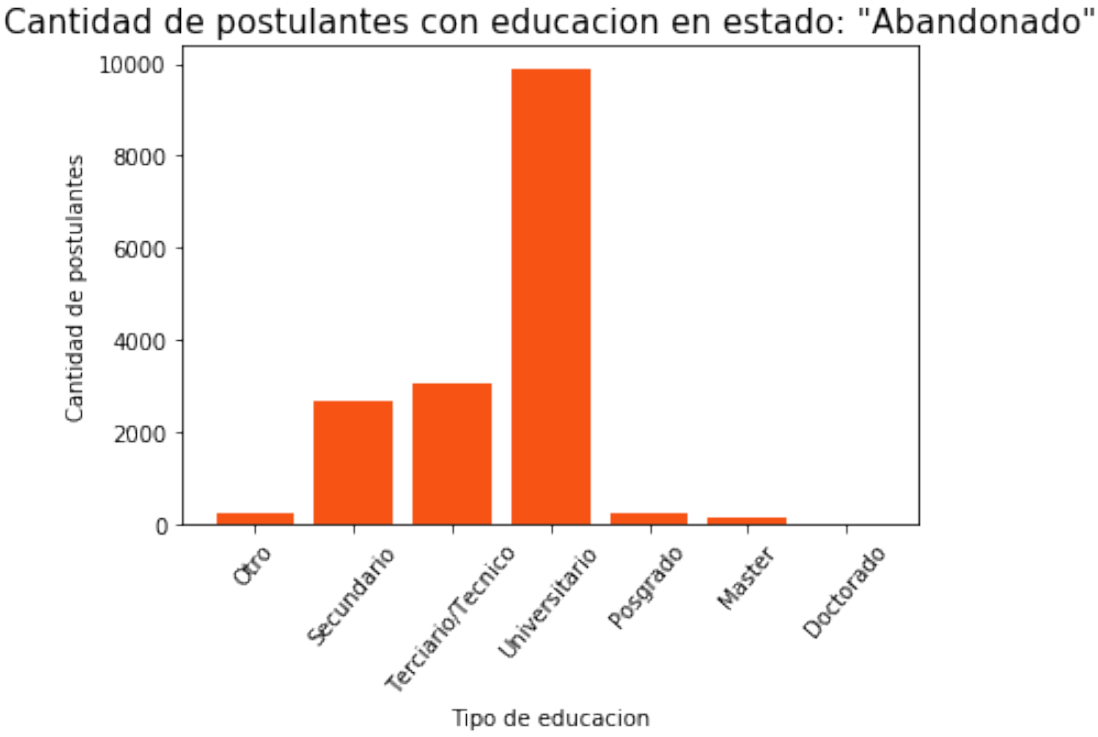
Cantidad de postulantes con educacion en estado: "Abandonado"
Cantidad de postulantes
10000
8000
6000
4000
2000
0
Otro
Secundario
Terciario/Tecnico
Universitario
Posgrado
Master
Doctorado
Tipo de educacion

Vemos que las distribuciones de los estados "En Curso" y "Abandonado" son muy similares, con un gran pico en Universitario (Tambien por la cantidad de casos). Sin embargo, la distribucion de "Graduado" tiene su pico en Secundario.

Para terminar con los estados, hacemos un gráfico con un resumen de todo esto

```
In [55]: fig, ax = plt.subplots(figsize = (15,10))
         width = 0.25

         postulantes_abandonado = []
         postulantes_encurso = []
         postulantes_graduado = []
         for nombre in nombres:

             postulantes_abandonado.append(postulantes_nombre['Abandonado'][nombre])
             #encurso
             postulantes_encurso.append(postulantes_nombre['En Curso'][nombre])
             #graduado
             postulantes_graduado.append(postulantes_nombre['Graduado'][nombre])

         abandonado = ax.bar(np.arange(len(nombres))-width, postulantes_abandonado, width, color
         encurso = ax.bar(np.arange(len(nombres)), postulantes_encurso, width, color = '#ffff1a'
         graduado = ax.bar(np.arange(len(nombres))+width, postulantes_abandonado, width, color =

         ax.set_xticks(np.arange(len(nombres)))
         ax.set_xticklabels(nombres,rotation=0)

         ax.legend((abandonado[0], encurso[0], graduado[0]), ('Abandonado', 'En Curso', 'Graduad
         ax.set_ylabel('Cantidad de postulantes', size = 15)
         ax.set_xlabel('Tipo de educacion', size = 15)
         ax.set_title('Educacion de los candidatos', size = 20)

Out[55]: <matplotlib.text.Text at 0x7f77df88a250>
```

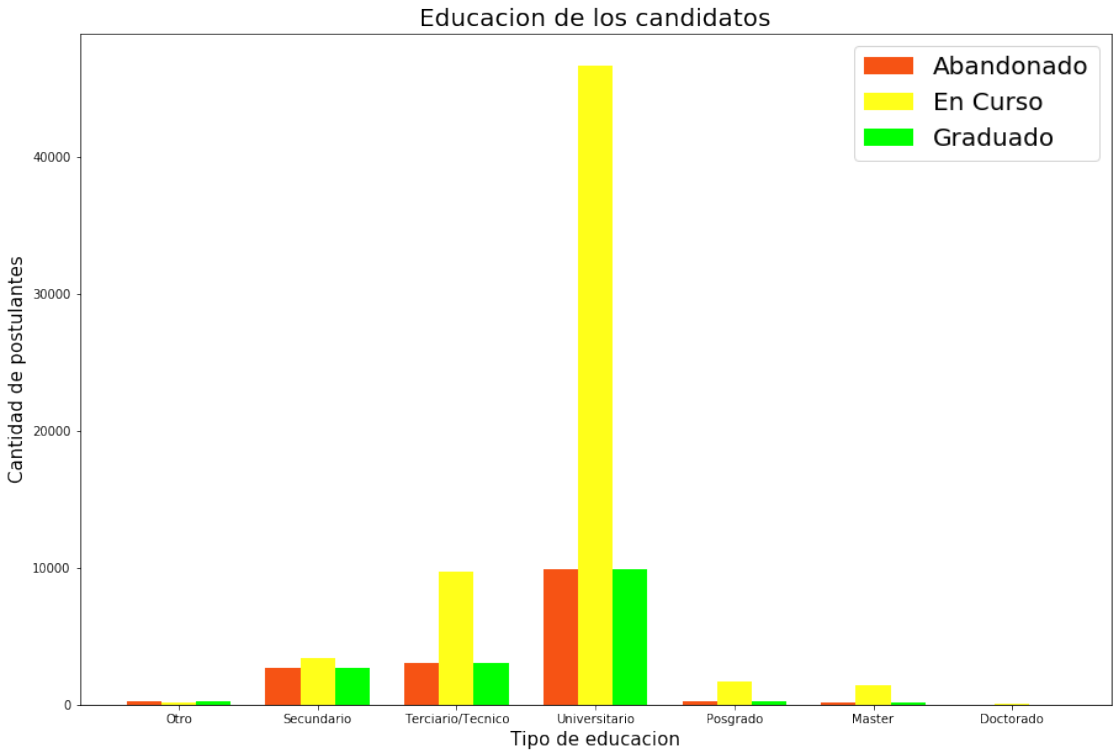

2.1 Analizamos el set de datos: "postulantes_genero_y_edad"

```
In [2]: postulantes_genero_edad = pd.read_csv("/home/luupesado/7506_Datos/2018/datos_navent_fiub
```

Vemos que forma tienen los datos

```
In [3]: postulantes_genero_edad.head()
```

```
Out[3]:   idpostulante fechanacimiento  sexo
        0         NM5M      1970-12-03   FEM
        1         5awk      1962-12-04   FEM
        2         ZaO5      1978-08-10   FEM
        3         NdJl      1969-05-09  MASC
        4         eo2p      1981-02-16  MASC
```

Pedimos un poco más información acerca de los datos que tenmos

```
In [4]: postulantes_genero_edad.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200888 entries, 0 to 200887
Data columns (total 3 columns):
idpostulante       200888 non-null object
fechanacimiento    196138 non-null object
```

```
sexo                200888 non-null object
dtypes: object(3)
memory usage: 4.6+ MB
```

Vemos que nos faltan algunos datos de la fecha de nacimiento de los postulantes, por ahora vamos a ver el sexo y nos los vamos a quedar

```
In [6]: postulantes_genero_edad['sexo'].value_counts()
```

```
Out[6]: FEM           101981
        MASC           94339
        NO_DECLARA      4568
        Name: sexo, dtype: int64
```

Vamos a hacer un gráfico que nos muestre mejor las cantidades

```
In [9]: fig, ax = plt.subplots()
        ax.bar(np.arange(3), postulantes_genero_edad['sexo'].value_counts(), color = ['#ff3399',
        ax.set_ylabel('Cantidad de postulantes')
        ax.set_xlabel('Sexo')
        ax.set_xticks(np.arange(3))
        ax.set_xticklabels( postulantes_genero_edad['sexo'].value_counts().index, rotation=0)
        ax.set_title('Cantidad de postulantes por orientacion sexual', size = 15)
```

```
Out[9]: <matplotlib.text.Text at 0x7fa5402997d0>
```

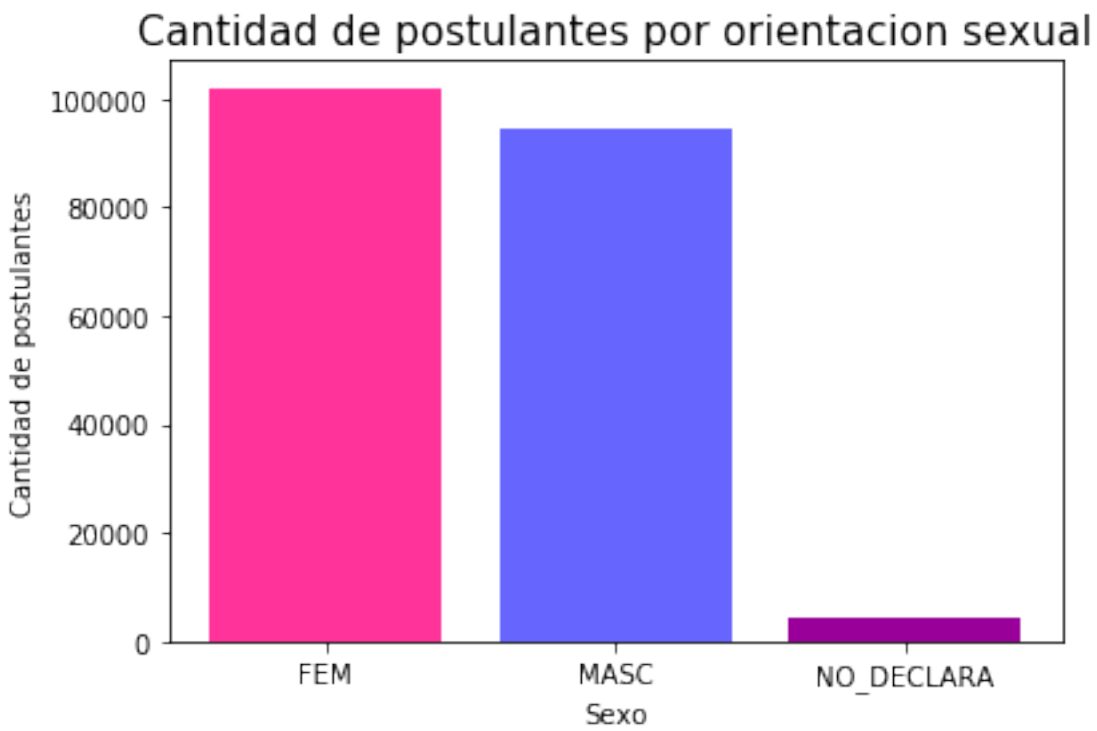

Ahora quitamos a los postulantes que no declaran el genero y la edad y hacemos un piechart con el porcentaje de hombres y mujeres

```
In [10]: femenino=postulantes_genero_edad[postulantes_genero_edad["sexo"]=="FEM"]
         masculino=postulantes_genero_edad[postulantes_genero_edad["sexo"]=="MASC"]

In [11]: sizes = [femenino.sexo.count(), masculino.sexo.count()]
         nombres = ['Femenino', 'Masculino']

         plt.figure(figsize=(9, 9))
         plt.title('Distribucion de genero en los postulantes', fontsize=20)
         plt.pie(sizes, labels=nombres, autopct='%1.1f%%', startangle=20, colors=['#ff3399', '#6
         plt.show()
```

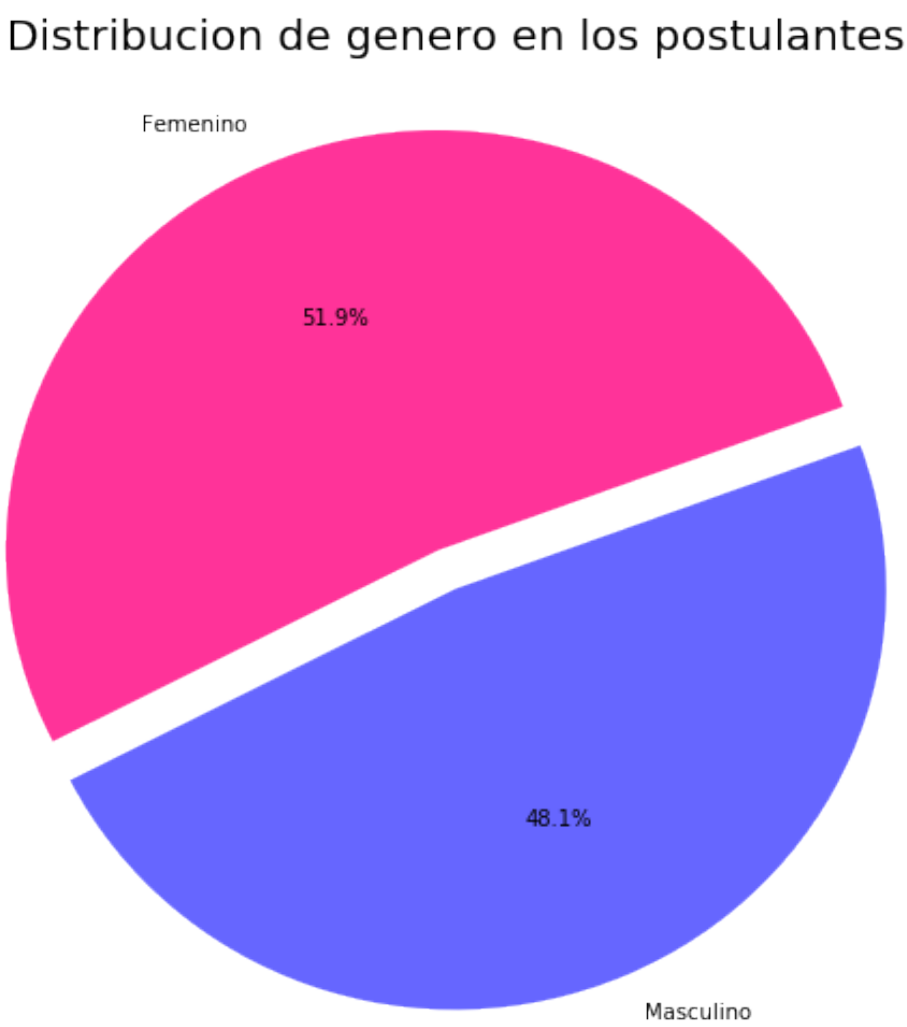

Hay un porcentaje de hombres levemente menor, pero se acerca a la mitad La fecha de naciemiento la usamos para calcular la edad de los postulantes. Para esto usamos spark, ya que era una de las consignas del finger 2.

```
In [2]: postulantes = sc.textFile('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_2_po

In [3]: import datetime as dt

In [4]: def strdate_to_age(string):
            try:
                date = dt.datetime.strptime(string, "%Y-%m-%d")
                today = dt.datetime(2018, 4, 1)
                edad = today.year - date.year
                if today.month >= date.month and today.day >= date.day:
                    edad = edad +1
                return edad
            except:
                return 0
```

Spark nos permite hacer muchas cosas en una sola linea. Comenzamos quitando la columna de header, luego convertimos la fecha de naciemiento a edad con la funcion que creamos arriba, y terminamos quitando a los postulantes menosres de 17 años y a los mayores de 100

```
In [10]: postulantes_edad = postulantes.map(lambda x: x.split(',')) \
                                      .filter(lambda x: x[0] != 'idpostulante')\
                                      .map(lambda y: (strdate_to_age(y[1]), 1)) \
                                      .filter(lambda z: (z[0] <100 and z[0]>16))
```

Vemos que nos queda un dato con la edad de cada postulante y un 1 (estos unos los vamos a usar para sumar y así contar la cantidad de personas con cada edad)

```
In [11]: postulantes_edad.take(5)

Out[11]: [(48, 1), (56, 1), (40, 1), (49, 1), (37, 1)]

In [12]: postulantes_edad = postulantes_edad.reduceByKey(lambda a, b: a+b)

In [13]: postulantes_edad = postulantes_edad.takeOrdered(61, lambda a: a[0])
```

Vemos que nos quedó una lista de tuplas con las edades y la cantidad de postulantes de cada edad

```
In [15]: postulantes_edad

Out[15]: [(18, 566),
          (19, 3625),
          (20, 6449),
          (21, 8503),
```

```
(22, 9927),
(23, 10874),
(24, 11586),
(25, 11680),
(26, 11804),
(27, 11923),
(28, 11099),
(29, 9890),
(30, 9179),
(31, 8309),
(32, 7643),
(33, 6679),
(34, 5879),
(35, 5450),
(36, 5024),
(37, 4661),
(38, 4189),
(39, 3883),
(40, 3384),
(41, 2933),
(42, 2641),
(43, 2356),
(44, 1979),
(45, 1692),
(46, 1564),
(47, 1462),
(48, 1277),
(49, 1098),
(50, 944),
(51, 874),
(52, 751),
(53, 662),
(54, 646),
(55, 552),
(56, 478),
(57, 447),
(58, 376),
(59, 286),
(60, 233),
(61, 182),
(62, 163),
(63, 96),
(64, 73),
(65, 37),
(66, 30),
(67, 19),
(68, 30),
(69, 12),
```

```
 (70, 9),
 (71, 7),
 (72, 2),
 (74, 3),
 (75, 2),
 (76, 3),
 (77, 1),
 (79, 1),
 (97, 1)]
```

Vamos a graficar esto para ver la distribucion de edades de los pustulantes

```
In [17]: edades = []
         count = []
         edad = 18
         i = 0
         while edad <= postulantes_edad[-1][0]:
             edades.append(edad)
             if postulantes_edad[i][0] == (edad):
                 count.append(postulantes_edad[i][1])
                 i = i+1
                 edad = edad + 1
             else:
                 count.append(0)
                 edad = edad + 1
```

```
In [20]: fig, ax = plt.subplots(figsize = (20,7))
         width = 0.35
         ax.set_xticks(np.arange(len(edades)) + width)
         ax.set_xticklabels(edades)
         ax.set_title('Edad de los postulantes', size = 20)
         ax.set_xlabel('Edad', size = 15)
         ax.set_ylabel('Cantidad de postulantes', size = 15)
         ax.bar(np.arange(len(edades))+width, count, color = ['#f65314', '#00ff00', '#0080ff', '
```

```
Out[20]: <Container object of 80 artists>
```

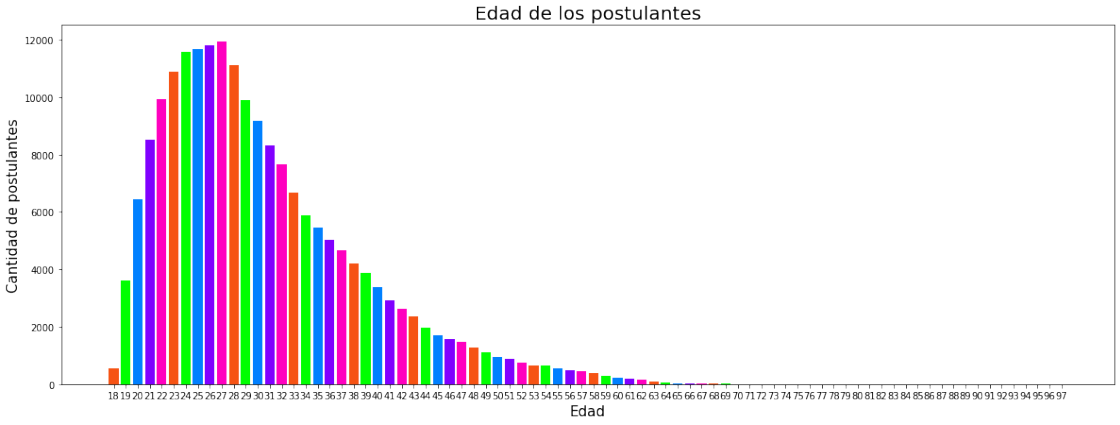

Vemos una especie de campana en la distribucion, con un lindo máximo en los 27. ESto de que se vean bastantes postulantes jóvenes, encaja con el hecho de que el nivel de estudios de la mayoría de los postulantes sea o secundario graduado, o universitario en curso.

2.2 Analizamos el set de datos: "vistas"

```
In [2]: vistas = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_3_vistas.
```

Vemos como está formado el dataset

```
In [3]: vistas.head()
```

```
Out[3]:       idAviso                     timestamp idpostulante
        0  1111780242  2018-02-23T13:38:13.187-0500      YjVJQ6Z
        1  1112263876  2018-02-23T13:38:14.296-0500      BmVpYoR
        2  1112327963  2018-02-23T13:38:14.329-0500      wVkBzZd
        3  1112318643  2018-02-23T13:38:17.921-0500      OqmP9pv
        4  1111903673  2018-02-23T13:38:18.973-0500      DrpbXDP
```

Mas en detalle...

```
In [4]: vistas.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 961897 entries, 0 to 961896
Data columns (total 3 columns):
idAviso         961897 non-null int64
timestamp       961897 non-null object
idpostulante    961897 non-null object
dtypes: int64(1), object(2)
memory usage: 22.0+ MB
```

Decidimos separar el timestamp en dos columnas, una con la fecha y otra con el horario

```
In [5]: def separar_fecha(fecha):
            nueva_fecha=fecha.split("T")
            return nueva_fecha[0]
        def separar_horario(fecha):
            nueva_fecha=fecha.split("T")
            dato=nueva_fecha[1]
            nuevo_horario=dato.split("-")
            return nuevo_horario[0]
```

```
In [6]: vistas["nueva_fecha"]=vistas["timestamp"].map(separar_fecha)
        vistas["nuevo_horario"]=vistas["timestamp"].map(separar_horario)
```

Nos queda así:

```
In [7]: vistas.head()
```

```
Out[7]:       idAviso                    timestamp idpostulante nueva_fecha  \
        0  1111780242  2018-02-23T13:38:13.187-0500      YjVJQ6Z  2018-02-23
        1  1112263876  2018-02-23T13:38:14.296-0500      BmVpYoR  2018-02-23
        2  1112327963  2018-02-23T13:38:14.329-0500      wVkBzZd  2018-02-23
        3  1112318643  2018-02-23T13:38:17.921-0500      OqmP9pv  2018-02-23
        4  1111903673  2018-02-23T13:38:18.973-0500      DrpbXDP  2018-02-23

          nuevo_horario
        0  13:38:13.187
        1  13:38:14.296
        2  13:38:14.329
        3  13:38:17.921
        4  13:38:18.973
```

Ahora lo convertimos a fechas y horarios de tipo datetime

```
In [8]: vistas["nueva_fecha"]=pd.to_datetime(vistas["nueva_fecha"])
        vistas["nuevo_horario"]=pd.to_datetime(vistas["nuevo_horario"])
```

```
In [9]: import calendar
        def dia_de_semana(fecha):
            return calendar.day_name[fecha.weekday()]
```

Vamos a ver que días de la semana hay más vistas a los anuncios

```
In [10]: vistas["dia"]=vistas["nueva_fecha"].map(dia_de_semana)
```

```
In [11]: vistas["dia"].value_counts()
```

```
Out[11]: Monday       240783
         Tuesday      230947
         Wednesday    226826
         Sunday       105245
         Saturday      90349
         Friday        67747
         Name: dia, dtype: int64
```

Nos llama la atencion que no haya ningun dato de vistas para el día jueves, sospchamos que tal vez hay información de menos de una semana.

```
In [12]: vistas["nueva_fecha"].value_counts()
```

```
Out[12]: 2018-02-26    240783
         2018-02-27    230947
         2018-02-28    226826
         2018-02-25    105245
         2018-02-24     90349
         2018-02-23     67747
         Name: nueva_fecha, dtype: int64
```

Corroboramos que tenemos informacion unicamente del 23/2 al 26/2

```
In [13]: vistas["dia"] = vistas["dia"].astype('category')
```

Ordenamos los días así, porque tenesmo datos de menos de una semana y los vamos a poner en orden de fecha

```
In [14]: categories_order = ['Friday','Saturday','Sunday','Monday', 'Tuesday', 'Wednesday']

In [15]: vistas["dia"] = vistas["dia"].cat \
                                      .set_categories(categories_order, ordered = True)

In [16]: vistas = vistas.sort_values('dia')

In [17]: vistas_group = vistas.groupby('dia')['idpostulante'].count()

In [18]: vistas_group

Out[18]: dia
         Friday        67747
         Saturday      90349
         Sunday       105245
         Monday       240783
         Tuesday      230947
         Wednesday    226826
         Name: idpostulante, dtype: int64

In [19]: y = [vistas_group.Friday,vistas_group.Saturday, vistas_group.Sunday, vistas_group.Monda

In [20]: fig, ax = plt.subplots()
         ax.set_xticks(np.arange(7))
         ax.set_xticklabels(['Friday \n 23/2', 'Saturday \n 24/2', 'Sunday \n 25/2', 'Monday \n

         ax.bar(np.arange(6), y ,color= ['#ffff00', '#66ff33', '#ff3333', '#0066ff', '#cc33ff',
         plt.title('Cantidad de visitas segun el dia', fontsize=22);
         plt.xlabel('Dia de la semana', fontsize=18);
         plt.ylabel('Cantidad de visitas', fontsize=20)

Out[20]: <matplotlib.text.Text at 0x7f022e26ac10>
```

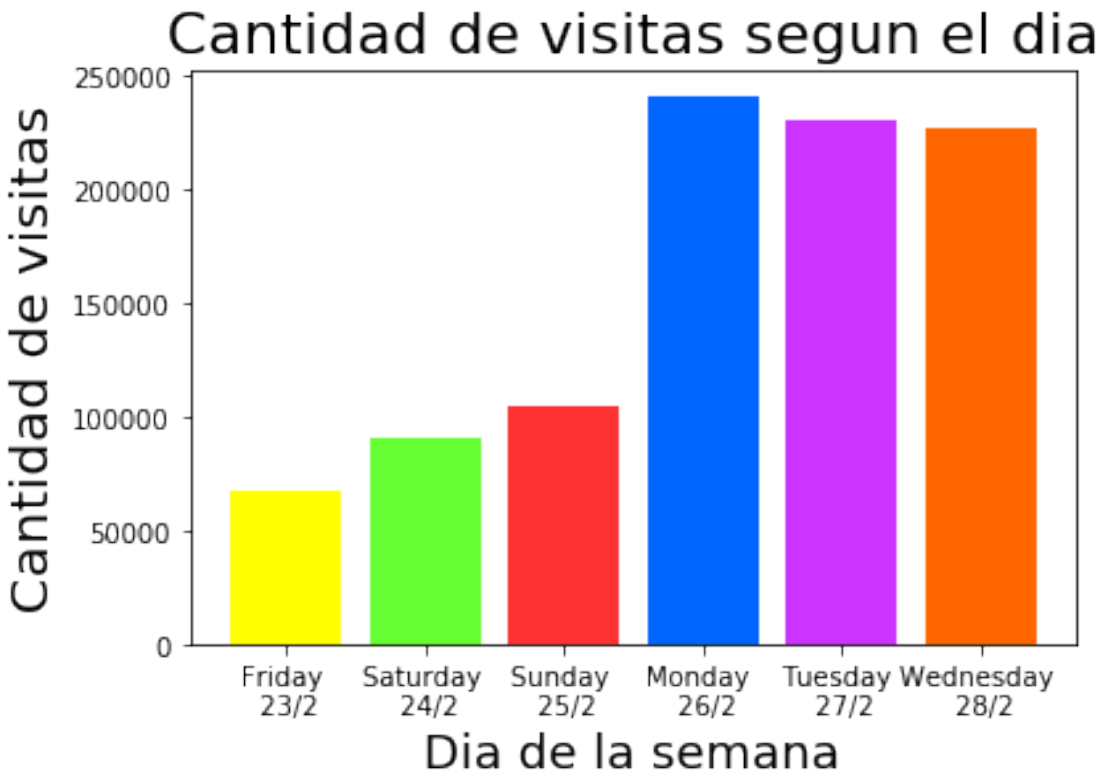

Los últimos 3 días, días de semana, hubo muchas más visitas que los demás días
Hacemos un conteo por hora

```
In [21]: vistas["hora"]=vistas["nuevo_horario"].dt.hour

In [22]: semana=vistas.loc[:,["hora","dia"]]

In [23]: semana["cantidad"]=semana["hora"].map(lambda x:1)
         semana_contador=semana.groupby("hora").aggregate(sum)

In [24]: semana_contador.plot(rot=0,figsize=(15,10),color="#0066ff",fontsize=14,grid=True);
         plt.title('Cantidad de visitas segun el horario', fontsize=22);
         plt.xlabel('Horario', fontsize=20);
         plt.ylabel('Cantidad de visitas', fontsize=20);
```

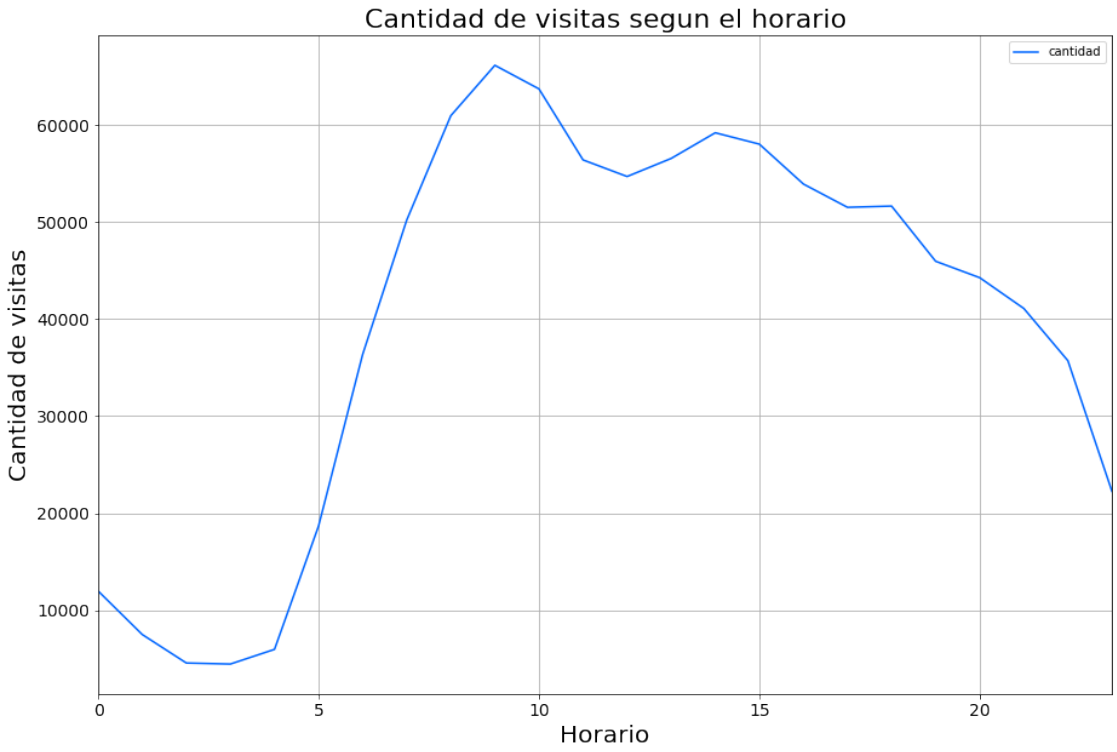

Vemos que, logicamente hay mayor cantidad de visitas a la mañana temprano, bajan durante el mediodía, suben nuevamente a la tarde y hay muy poscas durante la madrugada.

2.3 Analizamos el dataset: "postulaciones"

```
In [21]: postulaciones = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_4
```

Vemos como están compuestas las filas

```
In [34]: postulaciones.head()
```

```
Out[34]:       idaviso idpostulante     fechapostulacion
         0  1112257047         NM5M  2018-01-15 16:22:34
         1  1111920714         NM5M  2018-02-06 09:04:50
         2  1112346945         NM5M  2018-02-22 09:04:47
         3  1112345547         NM5M  2018-02-22 09:04:59
         4  1112237522         5awk  2018-01-25 18:55:03
```

Mas en detalle...

```
In [35]: postulaciones.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3401623 entries, 0 to 3401622
Data columns (total 3 columns):
```

```
idaviso             int64
idpostulante        object
fechapostulacion    object
dtypes: int64(1), object(2)
memory usage: 77.9+ MB
```

Vamos a convertir la fecha en formato fecha y agregar columnas con el día de la semana, el núemero de día y el núemero de mes

```
In [36]: postulaciones['fechapostulacion'] = pd.to_datetime(postulaciones['fechapostulacion'])
         postulaciones['dia'] = postulaciones['fechapostulacion'].dt.weekday_name
         postulaciones['mes'] = postulaciones['fechapostulacion'].dt.month
         postulaciones['numero_dia'] = postulaciones['fechapostulacion'].dt.day

In [37]: enero = postulaciones[postulaciones['mes']==1]
         febrero = postulaciones[postulaciones['mes']==2]

In [38]: print enero['numero_dia'].value_counts().index
         print febrero['numero_dia'].value_counts().index

Int64Index([24, 30, 29, 22, 23, 15, 31, 17, 16, 18, 25, 26, 19, 27, 28, 21,
            20],
           dtype='int64')
Int64Index([19, 20, 21, 26, 27, 28, 22, 15,  5,  6, 14, 23, 16,  1,  7,  2,  8,
             9, 25, 13, 24, 18, 17,  4, 12,  3, 10, 11],
           dtype='int64')
```

Vemos que los datos de enero son de la última quincena, por lo que vamos a separar los datos de febrero, tambien por quincena

```
In [39]: febrero_1quincena = febrero[febrero['numero_dia']<15]
         febrero_2quincena = febrero[febrero['numero_dia']>=15]

In [40]: postulaciones_group = postulaciones.groupby('dia')['idaviso'].count()

In [41]: x = ['Monday', 'Tuesday','Wednesday', 'Thursday',  'Friday', 'Saturday', 'Sunday']
         y = [postulaciones_group.Monday,postulaciones_group.Tuesday,postulaciones_group.Wednesd

In [42]: enero = enero.groupby(['mes','dia'])['idpostulante'].count()
         febrero_1quincena = febrero_1quincena.groupby(['mes','dia'])['idpostulante'].count()
         febrero_2quincena = febrero_2quincena.groupby(['mes','dia'])['idpostulante'].count()

In [43]: jan_y = [enero[1].Monday, enero[1].Tuesday, enero[1].Wednesday, enero[1].Thursday, ener
         feb1_y = [febrero_1quincena[2].Monday, febrero_1quincena[2].Tuesday, febrero_1quincena[
         feb2_y = [febrero_2quincena[2].Monday, febrero_2quincena[2].Tuesday, febrero_2quincena[
```

```
In [49]: fig, (ax1, ax2)=plt.subplots(2,1,sharex = True, figsize=(15,10))
         ax1.scatter(np.arange(7), y)
         ax1.set_xticks(np.arange(7))
         ax1.set_xticklabels(x,rotation='horizontal')
         ax2.set_xlabel('Dia de la semana', size =15)
         ax2.set_ylabel('Cantidad de Publicaciones', x=1,y=1, size = 15)

         width = 0.25
         jan = ax2.bar(np.arange(len(jan_y))-width, jan_y, width, color = '#3399ff')
         feb1 = ax2.bar(np.arange(len(feb1_y)), feb1_y, width, color = '#ff33cc')
         feb2 = ax2.bar(np.arange(len(feb2_y))+width, feb2_y, width, color = '#ffcc00')
         ax2.set_xticks(np.arange(7))
         ax2.set_xticklabels(x,rotation=85)

         ax2.legend((jan[0], feb1[0], feb2[0]), ('Enero 2da quincena', 'Febrero 1er quincena', '

         ax1.set_title('Cantidad de publicaciones por dia', size = 20)

Out[49]: <matplotlib.text.Text at 0x7f68ebbc3550>
```

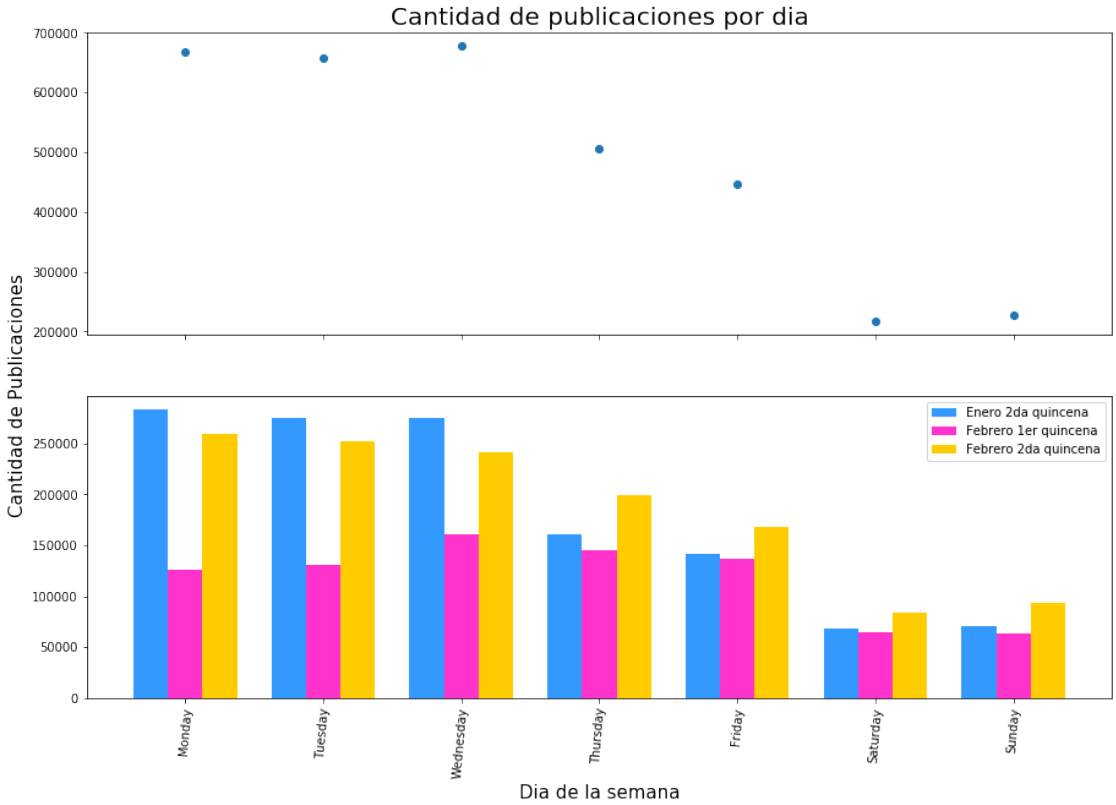

Vemos que se mantiene la tendencia que habíamos apensas sospechado con los pocos datos de las vistas: que durante el fin de semana las postulaciones tambien bajan, y son mayores los

primeros días de la semana. Nos llama la atencion las pocas postulaciones durante la primer quincena de febrero, en general

2.4 Analizamos el dataset: "avisos_online"

```
In [5]: avisos_online = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_5_
```

Vamos a ver que tiene

```
In [6]: avisos_online.head()
```

```
Out[6]:       idaviso
        0  1112355872
        1  1112335374
        2  1112374842
        3  1111984070
        4  1111822480
```

```
In [7]: avisos_online.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5028 entries, 0 to 5027
Data columns (total 1 columns):
idaviso    5028 non-null int64
dtypes: int64(1)
memory usage: 39.4 KB
```

Este set de datos solo contiene los ids de los avisos que se encuentran online. Hay 5028 avisos online

Agregamos una columna para indicar que el aviso es online cuando luego lo unamos con avisos_detalles

```
In [3]: avisos_online['online'] = True
```

2.5 Analizamos el dataset: "avisos_detalle"

```
In [26]: avisos_detalles = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba
```

Miro las primeras filas para ver que tine

```
In [10]: avisos_detalles.head()
```

```
Out[10]:       idaviso  idpais                                          titulo  \
         0     8725750       1               VENDEDOR/A PROVINCIA DE SANTA FE
         1    17903700       1                                     Enfermeras
         2  1000150677       1                                  Chofer de taxi
         3  1000610287       1  CHOFER DE CAMIONETA BAHIA BLANCA - PUNTA ALTA
         4  1000872556       1  Operarios de Planta - Rubro Electrodomésticos
```

```
                                          descripcion        nombre_zona  \
0  <p><strong><strong>Empresa:</strong></strong> ...  Gran Buenos Aires
1  <p>Solicitamos para importante cadena de farma...  Gran Buenos Aires
2  <p>TE GUSTA MANEJAR? QUERES GANAR PLATA HACIEN...    Capital Federal
3  <p><strong>Somos una empresa multinacional que...  Gran Buenos Aires
4  <p><strong>OPERARIOS DE PLANTA</strong></p><p>...  Gran Buenos Aires

  ciudad       mapacalle tipo_de_trabajo         nivel_laboral nombre_area  \
0    NaN             NaN       Full-time  Senior / Semi-Senior   Comercial
1    NaN             NaN       Full-time  Senior / Semi-Senior       Salud
2    NaN  Empedrado 2336       Full-time  Senior / Semi-Senior  Transporte
3    NaN             NaN       Full-time  Senior / Semi-Senior  Transporte
4    NaN             NaN       Full-time  Senior / Semi-Senior  Producción

      denominacion_empresa
0                   VENTOR
1  Farmacias Central Oeste
2              FAMITAX SRL
3      Wurth Argentina S.A
4       ELECTRO OUTLET SRL
```

Nos concentramos en sus columnas

```
In [11]: avisos_detalles.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 13534 entries, 0 to 13533
Data columns (total 11 columns):
idaviso                 13534 non-null int64
idpais                  13534 non-null int64
titulo                  13534 non-null object
descripcion             13534 non-null object
nombre_zona             13534 non-null object
ciudad                  47 non-null object
mapacalle               872 non-null object
tipo_de_trabajo         13534 non-null object
nivel_laboral           13534 non-null object
nombre_area             13534 non-null object
denominacion_empresa    13529 non-null object
dtypes: int64(2), object(9)
memory usage: 1.1+ MB
```

Vemos que las columnas 'ciudad' y 'nombre_zona' casi no tienen ocurrencias, por lo que no las vamos a usar. Además son muy pocas las filas a las que le falta denominación empresa, por lo que en un principio vaos a quitar estas filas tambien para tener los datos completos y hacer un mejor análisis inicial.

```
In [13]: avisos_detalles = avisos_detalles.dropna(axis = 0, subset = ['denominacion_empresa'], h
```

```
In [14]: avisos_detalles.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 13529 entries, 0 to 13533
Data columns (total 11 columns):
idaviso                 13529 non-null int64
idpais                  13529 non-null int64
titulo                  13529 non-null object
descripcion             13529 non-null object
nombre_zona             13529 non-null object
ciudad                  47 non-null object
mapacalle               872 non-null object
tipo_de_trabajo         13529 non-null object
nivel_laboral           13529 non-null object
nombre_area             13529 non-null object
denominacion_empresa    13529 non-null object
dtypes: int64(2), object(9)
memory usage: 1.2+ MB
```

2.5.1 Le damos un vistazo a cada columna

Así tendremos un mejor conocimiento del set de datos

```
In [15]: avisos_detalles['idaviso'].value_counts().head()
```

```
Out[15]: 1112381437    1
         1112306395    1
         1112226562    1
         1111335681    1
         1112320768    1
         Name: idaviso, dtype: int64
```

Como era de esperar, los ids son todos diferentes, por lo que no hay repetidos

```
In [16]: avisos_detalles['descripcion'].describe()
```

```
Out[16]: count                                                 13529
         unique                                                12669
         top       <p>Nos encontramos en la búsqueda de un ANALIS...
         freq                                                     19
         Name: descripcion, dtype: object
```

```
In [17]: avisos_detalles['titulo'].describe()
```

```
Out[17]: count                                                 13529
         unique                                                11645
         top       Analistas de Testing Ssr/Sr con Automatización...
         freq                                                     22
         Name: titulo, dtype: object
```

Estas columnas son muy dispersas, ya que vemos que hay casi tantos valores únicos como filas. Sin embargo nos llama la atención que, sobre todo en la columna 'descripción' hay algunos cuantos valores iguales

2.6 Columna: "tipo_de_trabajo"

```
In [18]: avisos_detalles['tipo_de_trabajo'].describe()
```

```
Out[18]: count         13529
         unique            9
         top       Full-time
         freq          12335
         Name: tipo_de_trabajo, dtype: object
```

```
In [19]: avisos_detalles['tipo_de_trabajo'].value_counts()
```

```
Out[19]: Full-time          12335
         Part-time            862
         Teletrabajo          110
         Pasantia              63
         Por Horas             63
         Temporario            42
         Por Contrato          37
         Fines de Semana       14
         Primer empleo          3
         Name: tipo_de_trabajo, dtype: int64
```

Ya que hay pocos valores posibles para esta columna, la vamos a convertir el tipo de dato en categoría, así ahorramos memoria y nos facilita algunos plots y análisis posteriores

```
In [20]: avisos_detalles['tipo_de_trabajo'] = avisos_detalles['tipo_de_trabajo'].astype('categor
```

También vamos a plasmar en un gráfico las apariciones de cada categoría

```
In [21]: def autolabel(rects, mysize):
             """
             Attach a text label above each bar displaying its height
             """
             for rect in rects:
                 width = rect.get_width()
                 ax.text(1.05*width,rect.get_y() + rect.get_height()/2.,
                         '%d' % int(width),
                         ha='left', va='center',size = mysize)
```

```
In [22]: values = avisos_detalles['tipo_de_trabajo'].value_counts().values
```

```
In [23]: indexes = avisos_detalles['tipo_de_trabajo'].value_counts().index
```

```
In [24]: indexes
```

```
Out[24]: CategoricalIndex([u'Full-time', u'Part-time', u'Teletrabajo', u'Por Horas',
                           u'Pasantia', u'Temporario', u'Por Contrato',
                           u'Fines de Semana', u'Primer empleo'],
                          categories=[u'Fines de Semana', u'Full-time', u'Part-time', u'Pasantia
```

```
In [25]: fig, ax = plt.subplots(figsize=(50,25))
         autolabel(ax.barh(np.arange(9), values , color = ['#ff1a1a', '#00ff00', '#0080ff', '#80
         ax.set_yticks(np.arange(9))
         ax.set_yticklabels(indexes, size = 45)
         ax.set_xticklabels([0, 2000,4000,6000,8000,10000,12000], size = 45)
         ax.set_title('Cantidad de avisos por modalidad de trabajo', size = 65)
         ax.set_xlabel('Cantidad de avisos', size = 45)
         ax.set_ylabel('Modalidad de trabajo', size = 45)
```

```
Out[25]: <matplotlib.text.Text at 0x7f3808259e10>
```

Como hay un gran porcentaje de trabajos ful-time, no se llega a ver bien la distribucion. Vamos a excluir los full-time en una nueva vizualización.

```
In [26]: values = avisos_detalles.loc[avisos_detalles['tipo_de_trabajo'] != 'Full-time']['tipo_d
```

```
In [27]: indexes = avisos_detalles.loc[avisos_detalles['tipo_de_trabajo'] != 'Full-time']['tipo_
```

```
In [28]: fig, ax = plt.subplots(figsize=(20,5))
         autolabel(ax.barh(np.arange(9), values ,   color = ['#00ff00', '#0080ff', '#8000ff', '#
         ax.set_yticks(np.arange(9))
         indexes = [ u'Part-time', u'Teletrabajo', u'Por Horas',
                           u'Pasantia', u'Temporario', u'Por Contrato',
                           u'Fines de Semana', u'Primer empleo']
         ax.set_yticklabels(indexes, size = 15)
         ax.set_xticklabels([0, 200,400,600,800], size = 15)
         ax.set_title('Cantidad de avisos por modalidad de trabajo (excluyendo full-time)', size
         ax.set_xlabel('Cantidad de avisos', size = 15)
         ax.set_ylabel('Modalidad de trabajo', size = 15)
```

```
Out[28]: <matplotlib.text.Text at 0x7f3803372ed0>
```

Los trabajos con modalidad full y part time, como era de esperar concentran a casi todos los avisos. Sin embargo nos resulta interesante que el tercer puesto se lo lleven los tele-trabajos.

2.7 Columna: "nombre_zona"

```
In [29]: avisos_detalles['nombre_zona'].describe()

Out[29]: count                 13529
         unique                    4
         top       Gran Buenos Aires
         freq                  12649
         Name: nombre_zona, dtype: object

In [30]: avisos_detalles['nombre_zona'].value_counts()

Out[30]: Gran Buenos Aires              12649
         Capital Federal                  876
         GBA Oeste                          2
         Buenos Aires (fuera de GBA)        2
         Name: nombre_zona, dtype: int64

In [31]: avisos_detalles['ciudad'].value_counts()

Out[31]: Buenos Aires               14
         Argentina                  13
         CABA                        3
         Capital Federal             2
         San Isidro                  2
         Vicente Lopez               1
         Mendoza                     1
         Santa Rosa                  1
         La Plata                    1
         Tortuguitas                 1
         Parque Patricios            1
         Barracas                    1
```

```
Microcentro                 1
paternal                    1
República Argentina         1
Buenos Aires Province       1
caba                        1
Zárate, Campana, Escobar    1
Name: ciudad, dtype: int64
```

Casi todos los trabajos se concentran en Gran Buenos Aires y Capital Federal. Sin embargo tomamos estos datos "con pinzas" porque el "Gran Buenos Aires" incluye a la Capital federal, y a "GBA Oeste". Por ejemplo, tenemos ocurrencias que dicen "Gran Buenos Aires" en "nombre_zona" y "Capital Federal" en "ciudad", que por cierto es un campo que habíamos decidido descartar por la poca cantidad de datos. Por lo tanto no podemos saber tampoco si hay más avisos de GBA que sean particularmente de la CABA.

```
In [32]: avisos_detalles[avisos_detalles['nombre_zona'] == 'Gran Buenos Aires'][avisos_detalles[

/usr/local/lib/python2.7/dist-packages/ipykernel_launcher.py:1: UserWarning: Boolean Series key
  """Entry point for launching an IPython kernel.


Out[32]: idaviso                2
         idpais                 2
         titulo                 2
         descripcion            2
         nombre_zona            2
         ciudad                 2
         mapacalle              0
         tipo_de_trabajo        2
         nivel_laboral          2
         nombre_area            2
         denominacion_empresa   2
         dtype: int64
```

2.8 Columna: "nivel_laboral"

```
In [33]: avisos_detalles['nivel_laboral'].describe()

Out[33]: count                   13529
         unique                      5
         top       Senior / Semi-Senior
         freq                     9404
         Name: nivel_laboral, dtype: object

In [34]: avisos_detalles['nivel_laboral'].value_counts()

Out[34]: Senior / Semi-Senior    9404
         Junior                  2216
         Otro                     919
```

```
Jefe / Supervisor / Responsable          809
Gerencia / Alta Gerencia / Dirección     181
Name: nivel_laboral, dtype: int64
```

Ya que hay pocos valores posibles para esta columna, la vamos a convertir el tipo de dato en categoría, así ahorramos memoria y nos facilita algunos plots y análisis posteriores

```
In [35]: avisos_detalles['nivel_laboral'] = avisos_detalles['nivel_laboral'].astype('category')

In [36]: values = avisos_detalles['nivel_laboral'].value_counts().values
         indexes = avisos_detalles['nivel_laboral'].value_counts().index

In [37]: indexes = [u'Senior / Semi-Senior', u'Junior', u'Otro',
                    u'Jefe / Supervisor / Responsable',
                    u'Gerencia / Alta Gerencia / Direccion']

In [38]: fig, ax = plt.subplots(figsize=(20,10))
         autolabel(ax.barh(np.arange(len(values)), values , color = ['#ff1a1a', '#00ff00', '#008
         ax.set_yticks(np.arange(len(values)))
         ax.set_yticklabels(indexes, size = 25)
         ax.set_xticklabels([0, 2000,4000,6000,8000], size = 25)
         ax.set_title('Cantidad de avisos por nivel laboral', size = 45)
         ax.set_xlabel('Cantidad de avisos', size = 25)
         ax.set_ylabel('Nivel laboral', size = 25)

Out[38]: <matplotlib.text.Text at 0x7f3806f5f090>
```

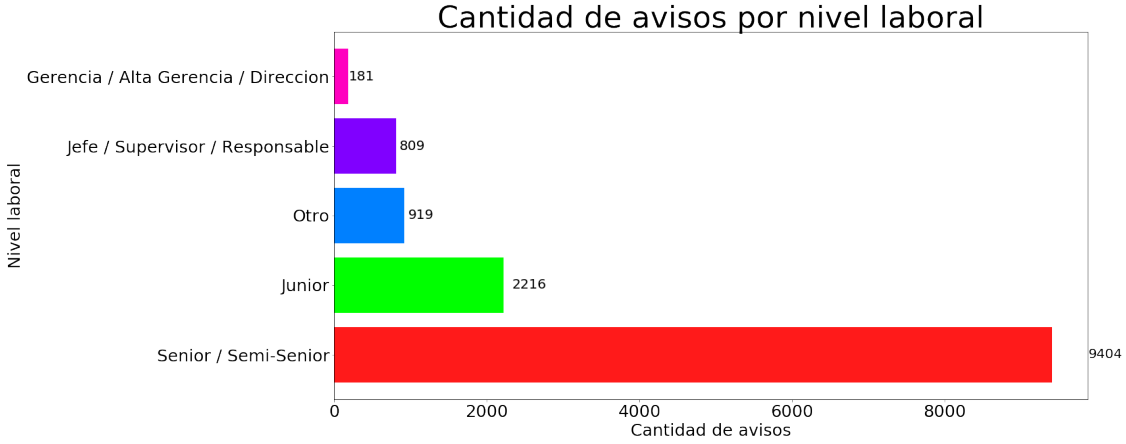

2.9 Columna: "nombre_area"

```
In [39]: avisos_detalles['nombre_area'].describe()

Out[39]: count      13529
         unique       173
```

```
top       Ventas
freq        1656
Name: nombre_area, dtype: object
```

```
In [40]: avisos_detalles['nombre_area'] = avisos_detalles['nombre_area'].astype('category')
```

```
In [41]: avisos_detalles['nombre_area'].value_counts().head(15)
```

```
Out[41]: Ventas                   1656
         Comercial                 982
         Administración            901
         Producción                820
         Programación              576
         Contabilidad              416
         Tecnologia / Sistemas     388
         Atención al Cliente       347
         Mantenimiento             324
         Recursos Humanos          235
         Gastronomia               234
         Oficios y Profesiones     209
         Soporte Técnico           203
         Logística                 200
         Call Center               191
         Name: nombre_area, dtype: int64
```

Si bien no hay tantas categorías, para graficar son demasiadas, por lo que vamos a graficar las 15 primeras

```
In [42]:  values = avisos_detalles['nombre_area'].value_counts().head(15).values
         indexes = avisos_detalles['nombre_area'].value_counts().head(15).index
```

```
In [43]: indexes = [u'Ventas', u'Comercial', u'Administracion', u'Produccion',
                u'Programacion', u'Contabilidad', u'Tecnologia / Sistemas',
                u'Atencion al Cliente', u'Mantenimiento', u'Recursos Humanos',
                u'Gastronomia', u'Oficios y Profesiones', u'Soporte Tecnico',
                u'Logistica', u'Call Center']
```

```
In [44]: fig, ax = plt.subplots()#figsize=(20,10))
         autolabel(ax.barh(np.arange(len(values)), values , color = ['#ff1a1a', '#00ff00', '#008
         ax.set_yticks(np.arange(len(values)))
         ax.set_yticklabels(indexes)#, size = 25)
         #ax.set_xticklabels([0, 2000,4000,6000,8000], size = 25)
         ax.set_title('Top 15 sectores con mas avisos', size = 20)
         ax.set_xlabel('Cantidad de avisos')#, size = 25)
         ax.set_ylabel('Sector/Area de trabajo')#, size = 25)
```

```
Out[44]: <matplotlib.text.Text at 0x7f38080ff890>
```

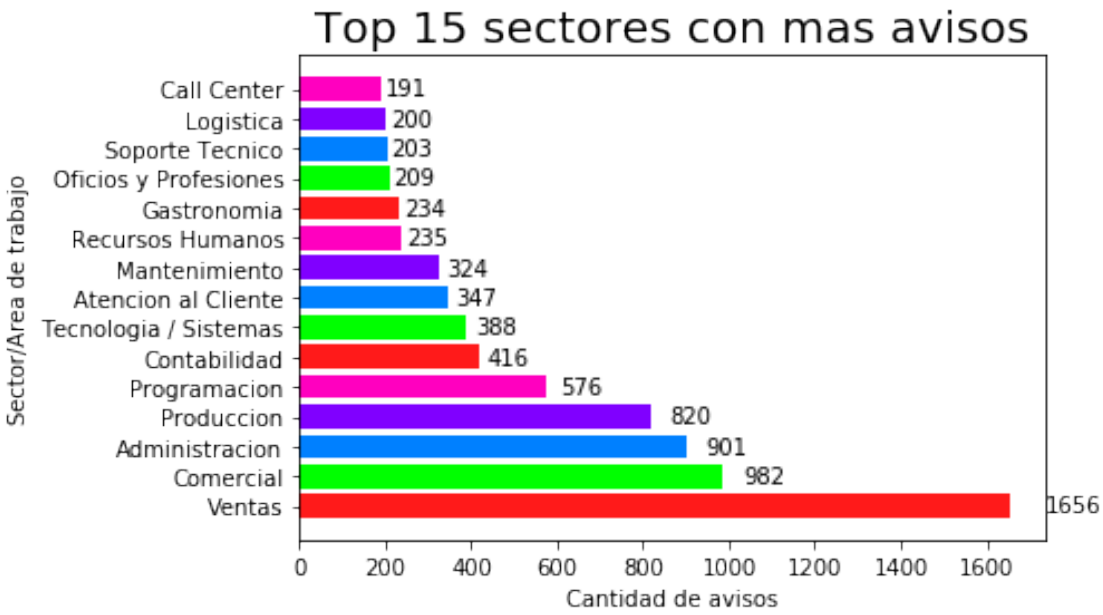

2.10 Columna: "denominacion_empresa"

```
In [45]: avisos_detalles['denominacion_empresa'].describe()
```

```
Out[45]: count         13529
         unique         2592
         top       RANDSTAD
         freq            562
         Name: denominacion_empresa, dtype: object
```

Si bien tenemos muchos valores diferentes, nos enocontramos con un número no tan grande de empresas: 2592

```
In [46]: avisos_detalles['denominacion_empresa'].value_counts()
```

```
Out[46]: RANDSTAD                                  562
         Manpower                                  422
         Grupo Gestión                             383
         Assistem                                  289
         SOLUTIX S.A.                              260
         BAYTON                                    238
         Pullmen Servicios Empresarios S.A.        229
         Adecco - Región NORTE & OESTE GBA         205
         Suministra                                203
         Adecco -Región Office                     200
         Consultores de Empresas SRL               197
         Adecco -Región GBA SUR                    160
```

Complement Group (holding)	160
Kaizen Recursos Humanos	110
Adecco -Región Litoral	109
CrossOver	109
IT Resources	109
Excelencia Laboral S.A.	98
Swiss Medical Group	88
Suple	88
Aliantec	81
Adecco - Región Centro Norte y Agro.	76
CONA CONSULTORES EN RRHH	75
RH Talentum	71
EAYA Consulting	71
Musimundo SA	71
ConfiaRH	63
AB InBev - Cervecería y Maltería Quilmes	63
BBVA Francés	63
Atento	62
	...
COSMÉTICA DEISEL SRL	1
VITALCAN S.A.	1
Estudio Contable Dichiara	1
Norfish	1
Reingenieria Comercial	1
Naum Citroen (concesionario Oficial)	1
Scienza Argentina	1
Agencia Oficial Lujan	1
kamet	1
COLLIERS INTERNATIONAL ARGENTINA	1
Valls Garden	1
POTTERY COFFEE & BAR	1
Modelina	1
SIAR INDUSTRIAL SRL	1
LATINOTCA.COM S.A.	1
Amican	1
DANSA SA	1
QUAY	1
Giro Didactico	1
Via Vespucci	1
durotech	1
mecubro	1
RED Real Estate Developers	1
Gani S.A.	1
BOART LONGYEAR ARGENTINA SA	1
Moni Online	1
Importante Empresa Gastronómica	1
Farmacia SSF	1
Consultora Aportes	1

```
Resolvit International                          1
Name: denominacion_empresa, Length: 2592, dtype: int64
```

```
In [47]:  values = avisos_detalles['denominacion_empresa'].value_counts().head(15).values
          indexes = avisos_detalles['denominacion_empresa'].value_counts().head(15).index
```

```
In [48]: indexes = [u'RANDSTAD', u'Manpower', u'Grupo Gestion', u'Assistem',
                    u'SOLUTIX S.A. ', u'BAYTON', u'Pullmen Servicios Empresarios S.A.',
                    u'Adecco - Region NORTE & OESTE GBA', u'Suministra',
                    u'Adecco -Region Office', u'Consultores de Empresas SRL',
                    u'Adecco -Region GBA SUR', u'Complement Group (holding)',
                    u'Kaizen Recursos Humanos', u'Adecco  -Región Litoral']
```

```
In [49]: fig, ax = plt.subplots()#figsize=(20,10))
         autolabel(ax.barh(np.arange(len(values)), values , color = ['#ff1a1a', '#00ff00', '#008
         ax.set_yticks(np.arange(len(values)))
         ax.set_yticklabels(indexes)#, size = 25)
         #ax.set_xticklabels([0, 2000,4000,6000,8000], size = 25)
         ax.set_title('Top 15 empresas con mas avisos', size = 20)
         ax.set_xlabel('Cantidad de avisos')#, size = 25)
         ax.set_ylabel('Sector/Area de trabajo')#, size = 25)
```

```
Out[49]: <matplotlib.text.Text at 0x7f3806e24990>
```

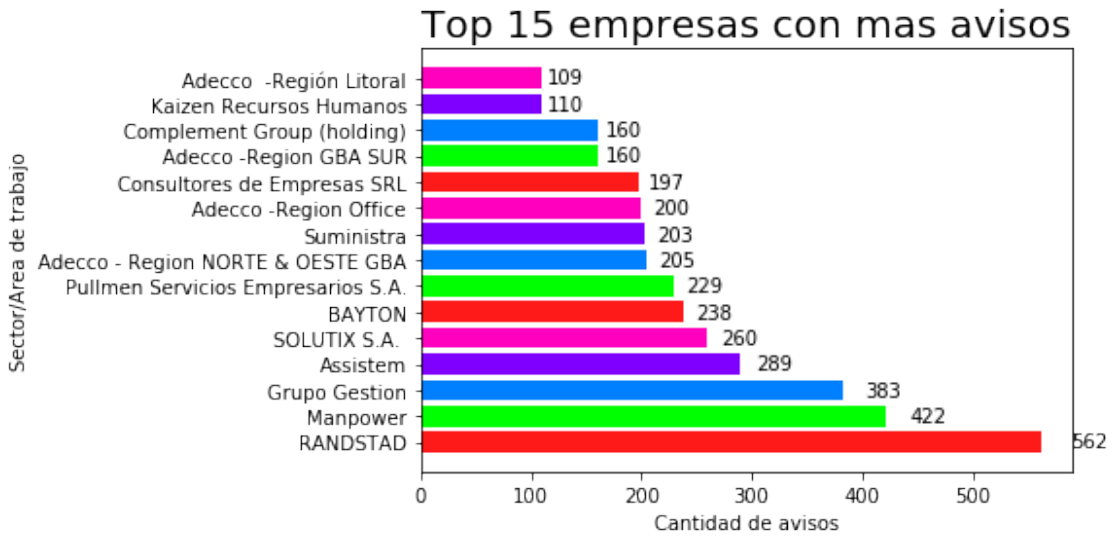

Vemos que todas las empresas que aparecen en los primeros puestos, son consultoras, lo cual tiene mucho sentido.

2.11 Relación entre columnas

Nos quedamos con las columnas que tienen datos, ya que en un principio vamos a analizar la relación entre las columnas claves.

```
In [50]: import unicodedata
         def elimina_tildes(s):
            return ''.join((c for c in unicodedata.normalize('NFD', s) if unicodedata.category(c

         def eliminar_tildes(keys):
             klist = []
             for k in keys:
                 klist.append(elimina_tildes(k.decode('utf-8')))

             return klist

In [51]: index = avisos_detalles['tipo_de_trabajo'].value_counts().index
         avisos_detalles['tipo_de_trabajo'] = avisos_detalles['tipo_de_trabajo'].cat\
                                              .set_categories(eliminar_tildes(index))
         avisos_detalles['tipo_de_trabajo'].value_counts().index

Out[51]: CategoricalIndex([u'Full-time', u'Part-time', u'Teletrabajo', u'Pasantia',
                           u'Por Horas', u'Temporario', u'Por Contrato',
                           u'Fines de Semana', u'Primer empleo'],
                          categories=[u'Full-time', u'Part-time', u'Teletrabajo', u'Por Horas',

In [52]: index = avisos_detalles['nivel_laboral'].value_counts().index
         avisos_detalles['nivel_laboral'] = avisos_detalles['nivel_laboral'].cat\
                                            .set_categories(eliminar_tildes(index))
         avisos_detalles['nivel_laboral'].value_counts().index

Out[52]: CategoricalIndex([u'Senior / Semi-Senior', u'Junior', u'Otro',
                           u'Jefe / Supervisor / Responsable',
                           u'Gerencia / Alta Gerencia / Direccion'],
                          categories=[u'Senior / Semi-Senior', u'Junior', u'Otro', u'Jefe / Supe

In [53]: pd.crosstab(index=avisos_detalles['tipo_de_trabajo'],
                     columns=[avisos_detalles['nivel_laboral']], margins=True)

Out[53]: nivel_laboral    Senior / Semi-Senior  Junior  Otro  \
         tipo_de_trabajo
         Full-time                        8885    1777   749
         Part-time                         372     350   132
         Teletrabajo                        57       1     1
         Por Horas                          39       8    15
         Pasantia                            4      49    10
         Temporario                         20      18     3
         Por Contrato                       17      10     5
         Fines de Semana                    10       1     3
         Primer empleo                       0       2     1
         All                              9404    2216   919

         nivel_laboral    Jefe / Supervisor / Responsable    All
         tipo_de_trabajo
```

```
Full-time                                745  12156
Part-time                                  7    861
Teletrabajo                               50    109
Por Horas                                  1     63
Pasantia                                   0     63
Temporario                                 1     42
Por Contrato                               5     37
Fines de Semana                            0     14
Primer empleo                              0      3
All                                      809  13348
```

In [54]:
```
import seaborn as sns
ax = plt.axes()
sns.heatmap(pd.crosstab(index=avisos_detalles['tipo_de_trabajo'],
                        columns=[avisos_detalles['nivel_laboral']], margins=True, norma
ax.set_title('Relacion entre las modalidades de trabajo y el nivel laboral requerido',
ax.set_xlabel('Nivel laboral')
ax.set_ylabel('Modalidad de trabajo')
```

Out[54]: <matplotlib.text.Text at 0x7f3806c30190>

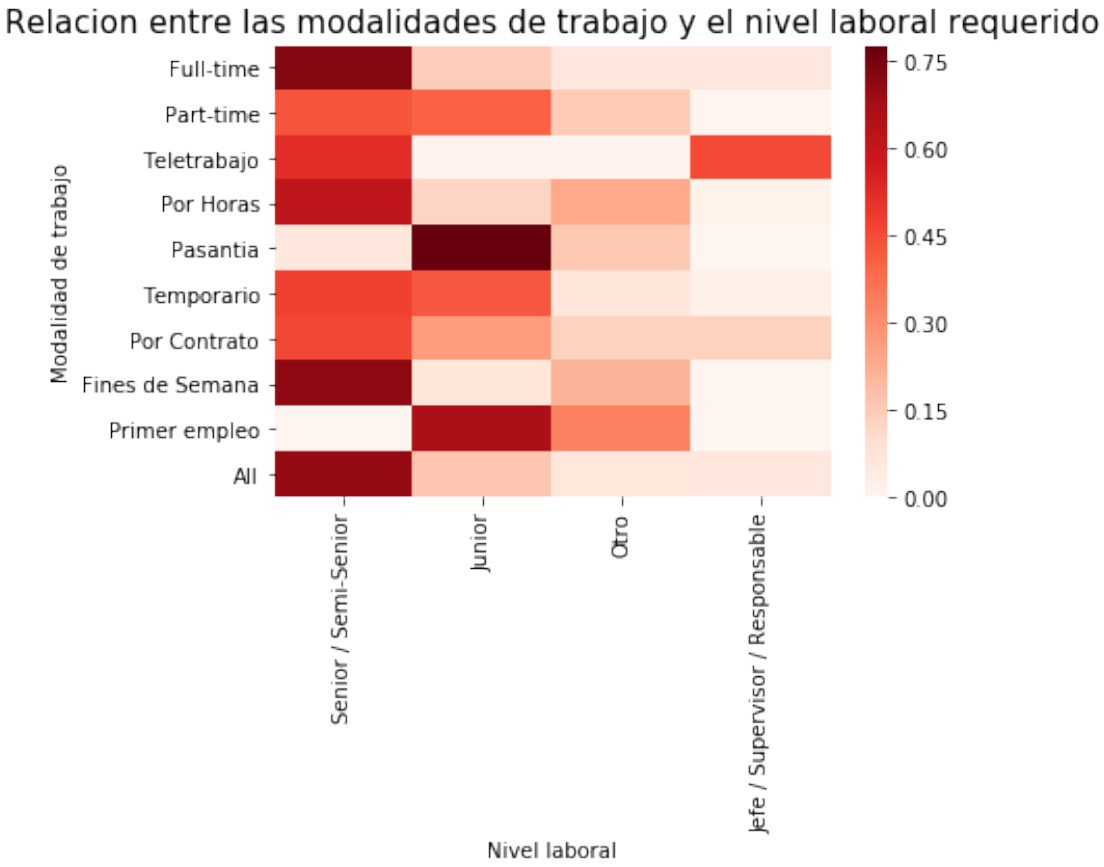

Cuanto más oscuro es el color en nuestro heatmap, más alta es la relacion que tienen entre sí. Observamos una gran correlación entre los puestos Senior y la modalidad full-time. Así como entre los puestos juniors y la spasantías y primeros empreos. Los Jefes y supervisores, si bien en la tabla se ve que casi siempre van de modalidad full-time, ocupan casi la mitad de los cargos con modalidad teletrabajo, lo cual nos llama un poco la atención.

```
In [56]: index = avisos_detalles['nombre_area'].value_counts().head(15).index
         avisos_detalles['nombre_area'] = avisos_detalles['nombre_area'].cat\
                                             .set_categories(eliminar_tildes(index))
         avisos_detalles['nombre_area'].value_counts().index

Out[56]: CategoricalIndex([u'Ventas', u'Comercial', u'Contabilidad',
                           u'Tecnologia / Sistemas', u'Mantenimiento',
                           u'Recursos Humanos', u'Gastronomia',
                           u'Oficios y Profesiones', u'Call Center', u'Logistica',
                           u'Soporte Tecnico', u'Atencion al Cliente', u'Programacion',
                           u'Produccion', u'Administracion'],
                          categories=[u'Ventas', u'Comercial', u'Administracion', u'Produccion',

In [57]: pd.crosstab(index=avisos_detalles['tipo_de_trabajo'],
                     columns=[avisos_detalles['nombre_area']], margins=True)

Out[57]: nombre_area      Ventas  Comercial  Contabilidad  Tecnologia / Sistemas  \
         tipo_de_trabajo
         Full-time          1384        926           397                    346
         Part-time           242         41            14                      6
         Teletrabajo          15          8             0                     34
         Por Horas             5          1             0                      0
         Pasantia              1          4             0                      0
         Temporario            3          2             4                      1
         Por Contrato          4          0             1                      1
         Fines de Semana       2          0             0                      0
         Primer empleo         0          0             0                      0
         All                1656        982           416                    388

         nombre_area      Mantenimiento  Recursos Humanos  Gastronomia  \
         tipo_de_trabajo
         Full-time                  323               223          219
         Part-time                    0                 7           12
         Teletrabajo                  0                 0            0
         Por Horas                    1                 1            1
         Pasantia                     0                 3            0
         Temporario                   0                 0            1
         Por Contrato                 0                 1            0
         Fines de Semana              0                 0            1
         Primer empleo                0                 0            0
         All                        324               235          234

         nombre_area      Oficios y Profesiones  Call Center   All
```

tipo_de_trabajo			
Full-time	198	66	4082
Part-time	10	125	457
Teletrabajo	0	0	57
Por Horas	0	0	9
Pasantia	0	0	8
Temporario	0	0	11
Por Contrato	1	0	8
Fines de Semana	0	0	3
Primer empleo	0	0	0
All	209	191	4635

In [58]:
```
ax = plt.axes()
sns.heatmap(pd.crosstab(index=avisos_detalles['tipo_de_trabajo'],
            columns=[avisos_detalles['nombre_area']], margins=True, normalize= 'index')
ax.set_title('Relacion entre las modalidades de trabajo y el area o sector', size = 15)
ax.set_xlabel('Nivel laboral')
ax.set_ylabel('Modalidad de trabajo')
```

Out[58]: <matplotlib.text.Text at 0x7f3806eaa390>

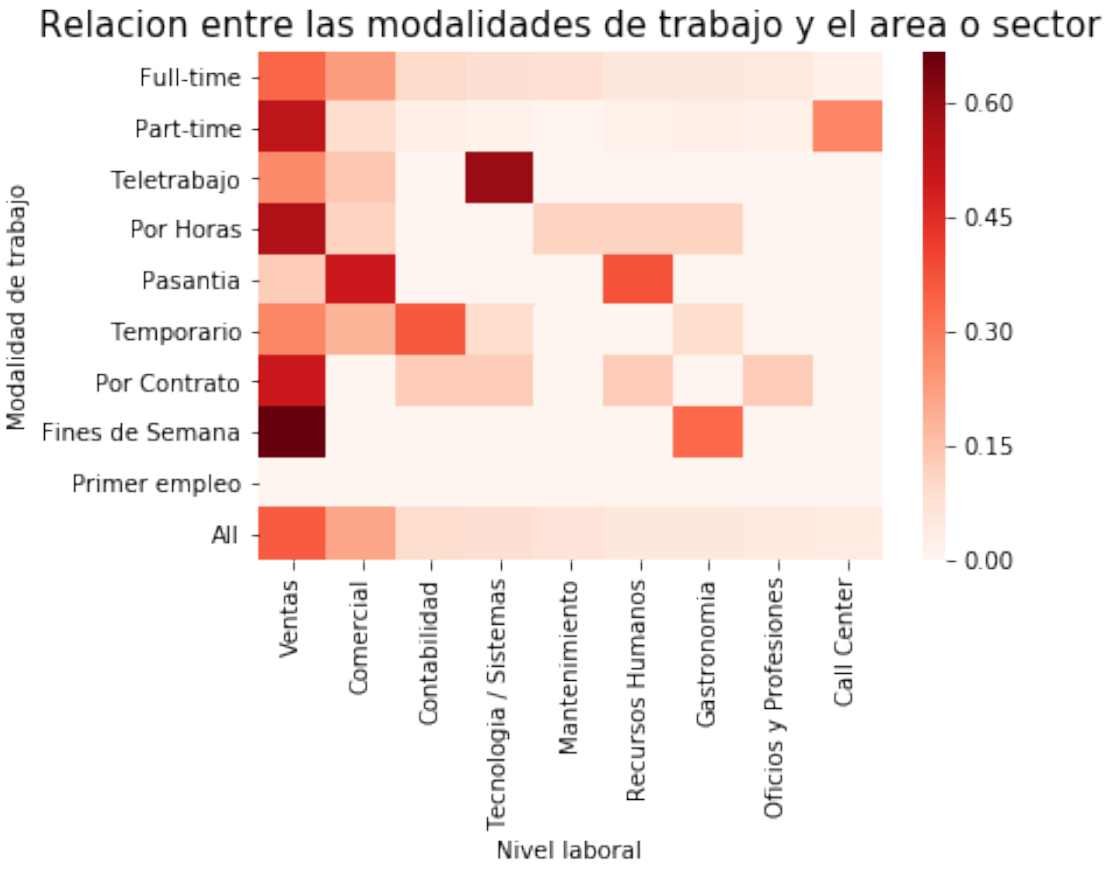

Resaltan las relaciones entre los empleos part-time y los call-centers; el teletrabajo y el area de sistemas; las pasantías en las areas comercial y recursos humanos; empleos temporarios en el area de ventas, comercial y de contabilidad; y los trabajos de fin de semana en el area de ventas y en el sector gastronómico.

Cremos que este análisis de la relacion entre columnas nos puede servir para el proximo tp de predicción

3 Análisis profundo

Habiendo analizado cada set de datos por separado, nos planteamos preguntas que relacionan mas de un set de datos

4 ¿Cuántos de los avisos de los que tenemos información se encuentran activos?

```
In [2]: avisos_online = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_5_
        avisos_detalles = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_
```

Unimos los sets de datos de avisos online y avisos detalles. Por lo que agregamos así una columna: "online" en la que se indica si el aviso está online

```
In [5]: avisos = avisos_detalles.join(avisos_online.set_index('idaviso'),on='idaviso',how='left'
```

```
In [6]: avisos.head()
```

```
Out[6]:       idaviso  idpais                                          titulo  \
        0     8725750       1               VENDEDOR/A PROVINCIA DE SANTA FE
        1    17903700       1                                      Enfermeras
        2  1000150677       1                                   Chofer de taxi
        3  1000610287       1  CHOFER DE CAMIONETA BAHIA BLANCA - PUNTA ALTA
        4  1000872556       1  Operarios de Planta - Rubro Electrodomésticos

                                             descripcion        nombre_zona  \
        0  <p><strong><strong>Empresa:</strong></strong> ...  Gran Buenos Aires
        1  <p>Solicitamos para importante cadena de farma...  Gran Buenos Aires
        2  <p>TE GUSTA MANEJAR? QUERES GANAR PLATA HACIEN...    Capital Federal
        3  <p><strong>Somos una empresa multinacional que...  Gran Buenos Aires
        4  <p><strong>OPERARIOS DE PLANTA</strong></p><p>...  Gran Buenos Aires

          ciudad       mapacalle tipo_de_trabajo         nivel_laboral nombre_area  \
        0    NaN             NaN       Full-time  Senior / Semi-Senior   Comercial
        1    NaN             NaN       Full-time  Senior / Semi-Senior       Salud
        2    NaN  Empedrado 2336       Full-time  Senior / Semi-Senior  Transporte
        3    NaN             NaN       Full-time  Senior / Semi-Senior  Transporte
        4    NaN             NaN       Full-time  Senior / Semi-Senior  Producción

             denominacion_empresa online
```

```
0                   VENTOR    NaN
1  Farmacias Central Oeste    NaN
2              FAMITAX SRL    NaN
3      Wurth Argentina S.A   True
4       ELECTRO OUTLET SRL    NaN
```

In [7]:
```
##Los que no son avisos online en la columna online tiene valor False
avisos["online"].fillna(False,inplace=True)
avisos.head()
```

Out[7]:
```
      idaviso  idpais                                          titulo  \
0     8725750       1              VENDEDOR/A PROVINCIA DE SANTA FE
1    17903700       1                                     Enfermeras
2  1000150677       1                                  Chofer de taxi
3  1000610287       1  CHOFER DE CAMIONETA BAHIA BLANCA - PUNTA ALTA
4  1000872556       1  Operarios de Planta - Rubro Electrodomésticos

                                          descripcion        nombre_zona  \
0  <p><strong><strong>Empresa:</strong></strong> ...  Gran Buenos Aires
1  <p>Solicitamos para importante cadena de farma...  Gran Buenos Aires
2  <p>TE GUSTA MANEJAR? QUERES GANAR PLATA HACIEN...    Capital Federal
3  <p><strong>Somos una empresa multinacional que...  Gran Buenos Aires
4  <p><strong>OPERARIOS DE PLANTA</strong></p><p>...  Gran Buenos Aires

  ciudad       mapacalle tipo_de_trabajo         nivel_laboral nombre_area  \
0    NaN             NaN       Full-time  Senior / Semi-Senior   Comercial
1    NaN             NaN       Full-time  Senior / Semi-Senior       Salud
2    NaN  Empedrado 2336       Full-time  Senior / Semi-Senior  Transporte
3    NaN             NaN       Full-time  Senior / Semi-Senior  Transporte
4    NaN             NaN       Full-time  Senior / Semi-Senior  Producción

      denominacion_empresa  online
0                   VENTOR   False
1  Farmacias Central Oeste   False
2              FAMITAX SRL   False
3      Wurth Argentina S.A    True
4       ELECTRO OUTLET SRL   False
```

In [9]:
```
sizes = [avisos[avisos["online"]==True]["online"].count(), avisos[avisos["online"]==Fals
nombres = ['Activo', 'No Activo']

plt.figure(figsize=(6, 6))
plt.title('Cantidad de visitas segun tipo de aviso', fontsize=20)
plt.pie(sizes, labels=nombres, autopct='%1.1f%%', colors=['Green', 'red'], explode=(0.1,
plt.show()
```

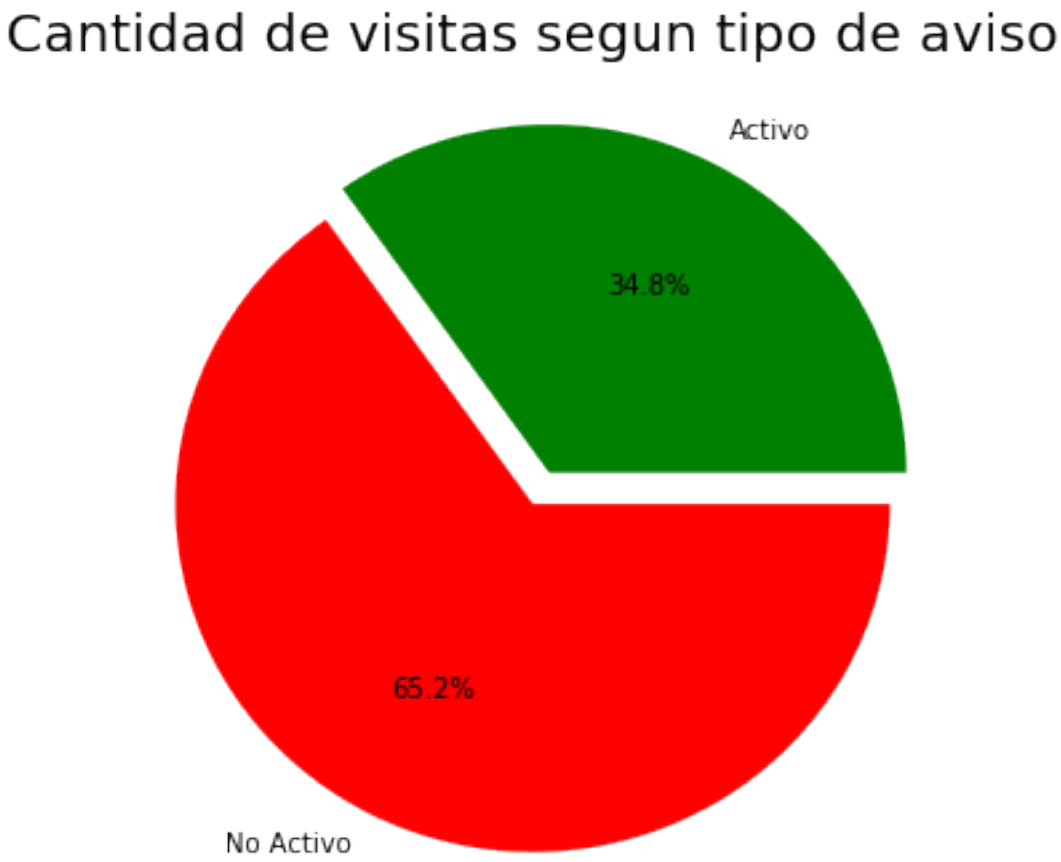

Vemos que los acisos que se encuentran activos representan aproximadamente un tercio de los avisos totales que tenemos

5 Los datos de vistas que tenemos ¿son todos de avisos activos?

```
In [10]: vistas = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_3_vistas

In [11]: avisos_online["online"] = True
         vistas_activas = vistas.join(avisos_online.set_index("idaviso"), on="idAviso", how='inn

In [12]: vistas_activas['online'].value_counts()

Out[12]: True    760068
         Name: online, dtype: int64
```

Deducimos que el data set de vistas sólo posee datos activos

5.1 ¿Cuales son los 5 avisos con mayor tasa de conversión?

Esta pregunta se encontraba tambien el el segundo finger, por lo que la hicimos en spark, tambien.

Llamamos tasa de conversio a las postulaciones al anuncio sobre las visitas totales que tuvo el mismo

```
In [3]: vistas = sc.textFile('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_3_vistas.
        postulaciones = sc.textFile('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_4_

In [4]: postulaciones.take(5)

Out[4]: [u'idaviso,idpostulante,fechapostulacion',
         u'1112257047,NM5M,2018-01-15 16:22:34',
         u'1111920714,NM5M,2018-02-06 09:04:50',
         u'1112346945,NM5M,2018-02-22 09:04:47',
         u'1112345547,NM5M,2018-02-22 09:04:59']

In [5]: vistas.take(5)

Out[5]: [u'idAviso,timestamp,idpostulante',
         u'1111780242,2018-02-23T13:38:13.187-0500,YjVJQ6Z',
         u'1112263876,2018-02-23T13:38:14.296-0500,BmVpYoR',
         u'1112327963,2018-02-23T13:38:14.329-0500,wVkBzZd',
         u'1112318643,2018-02-23T13:38:17.921-0500,OqmP9pv']
```

Averiguo para que periodo tengo tanto vistas como postulaciones, haciendo caso a la Nota 2.

Nota2: Tener en cuenta también que los datos de vistas están incompletos. Solo podrá obtenerse la tasa de conversión para el período donde se tengan ambas informaciones (postulaciones y vistas).

```
In [6]: vistas_periodo = vistas.map(lambda x: x.split(',')).map(lambda z: z[1].split('T')).map(l
```

Tengo vistas solo desde el 23/2 al 28/2

```
In [7]: postulaciones_periodo = postulaciones.map(lambda x: x.split(',')).map(lambda y: (y[2],1)

In [8]: postulaciones_periodo

Out[8]: [(u'2018-01-15 00:00:01', 1),
         (u'2018-01-15 00:00:02', 1),
         (u'2018-01-15 00:00:09', 1),
         (u'2018-01-15 00:00:10', 1),
         (u'2018-01-15 00:00:11', 1)]
```

Las Postulaciones comienzan el 15/1

Ahora voy a comenzar a resolver el ejercicio obteniendo la cantidad de visitas que tuvo cada aviso

```
In [9]: cant_vistas = vistas.map(lambda x: x.split(',')).map(lambda y: (y[0], 1)).reduceByKey(la

In [10]: cant_vistas.take(5)
```

```
Out[10]: [(u'1112366334', 557),
          (u'1112269789', 76),
          (u'1112312760', 84),
          (u'1112288001', 48),
          (u'1112192023', 8)]
```

Ahora calculo el promedio de la cantidad de visitas de cada aviso, haciendo caso a la Nota1 y evitando así equivocarme con "la ecuación más peligrosa de la historia", filtro los que tienen menos de un %25 de las visitas promedio.

Nota1: Tener en cuenta que es posible que por ejemplo un anuncio con una visita y una postulación quede primero. Para evitar este inconveniente, tomar únicamente los avisos que poseen al menos un 25% de las visitas promedio que poseen los avisos. Por ejemplo, si el promedio de visitas de los avisos es 100, tomar solo los avisos que tengan al menos 25 visitas.

```
In [11]: promedio = cant_vistas.map(lambda x: (1, x[1])).reduceByKey(lambda a,b: a+b)

In [12]: promedio.take(1)[0]

Out[12]: (1, 961898)

In [13]: promedio = promedio.take(1)[0][1]/cant_vistas.count()

In [14]: promedio

Out[14]: 128

In [15]: cant_vistas = cant_vistas.filter(lambda x: x[1]>(promedio/4))
```

Ahora calculo la cantidad de postulaciones para cada publicacion en ese período

```
In [16]: cant_postulaciones = postulaciones.map(lambda x: x.split(',')).map(lambda y: (y[0], y[2

In [17]: cant_postulaciones.take(5)

Out[17]: [(u'1112366334', 227),
          (u'1112269789', 19),
          (u'1112312760', 43),
          (u'1112312098', 18),
          (u'1112323355', 26)]
```

Ahora uno la cantidad de postulaciones con la cantidad de visitas para cada sitio para poder calcular la tasa de conversión. Corresponde un inner join ya que la consigna especifica que la tasa se calcule para los avisos que tengan tanto visitas como postulaciones.

```
In [18]: tasa = cant_postulaciones.join(cant_vistas).map(lambda x: (x[0], float(x[1][0])/float(x

In [19]: cant_postulaciones.join(cant_vistas).take(5)

Out[19]: [(u'1112366334', (227, 557)),
          (u'1112312760', (43, 84)),
          (u'1112323355', (26, 132)),
          (u'1112269789', (19, 76)),
          (u'1112335406', (142, 414))]
```

```
In [20]: tasa.take(5)
```

```
Out[20]: [(u'1112366334', 0.40754039497307004),
          (u'1112312760', 0.5119047619047619),
          (u'1112323355', 0.19696969696969696),
          (u'1112269789', 0.25),
          (u'1112335406', 0.34299516908212563)]
```

```
In [21]: mayor_tasa = tasa.takeOrdered(5, lambda x: -x[1])
```

```
In [22]: rdd_tasa = sc.parallelize(mayor_tasa)
```

```
In [23]: rdd_tasa.take(5)
```

```
Out[23]: [(u'1112355348', 2.0912052117263844),
          (u'1112365531', 1.6677814938684503),
          (u'1112343233', 1.5833333333333333),
          (u'1112299671', 1.5633802816901408),
          (u'1112357810', 1.4901960784313726)]
```

```
In [24]: bar_ids = rdd_tasa.map(lambda x: x[0]).take(5)
         bar_tasa = rdd_tasa.map(lambda y: y[1]).take(5)
         fig, ax = plt.subplots()
         ax.set_yticks([0,1,2,3,4])
         ax.set_yticklabels(bar_ids)
         ax.set_title('5 avisos con mayor tasa de conversion')
         ax.set_xlabel('Tasa de conversion')
         ax.set_ylabel('Id avisos')
         ax.barh([0,1,2,3,4], bar_tasa, color = ['#f65314', '#00ff00', '#0080ff', '#8000ff', '#f
```

```
Out[24]: <Container object of 5 artists>
```

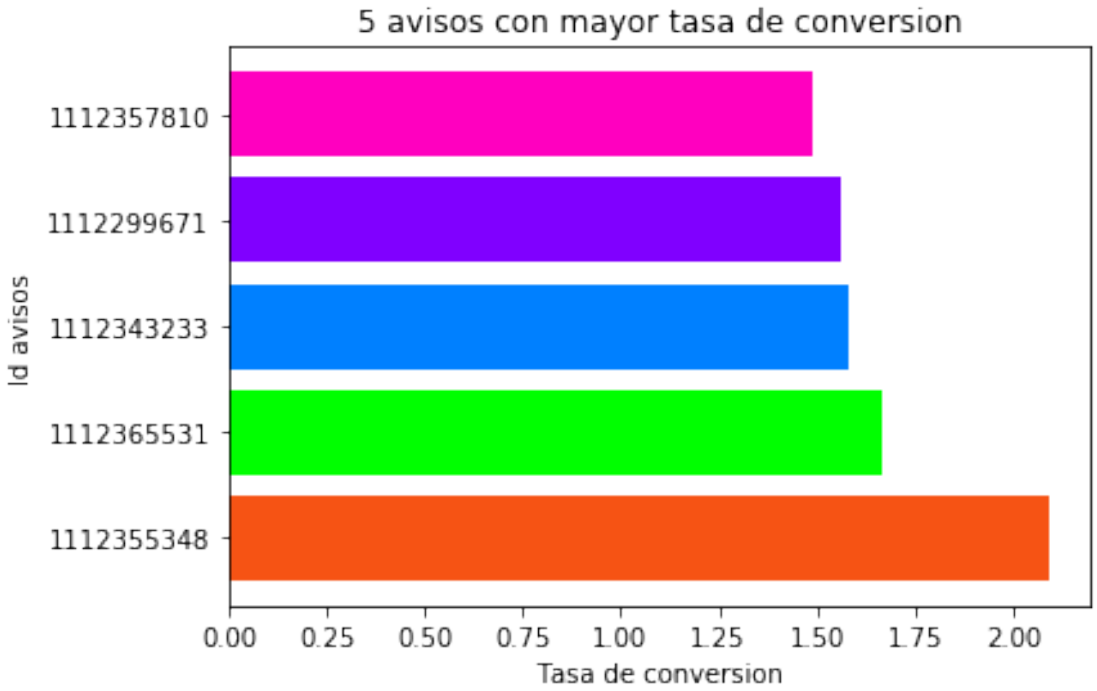

Averiguamos ahora, con pandas, que son cada uno de estos avisos. Desde el 5to al 1er pusto

```
In [28]: avisos_detalles.loc[avisos_detalles['idaviso'].isin(bar_ids)]
```

```
Out[28]:          idaviso  idpais                                              titulo  \
         1910  1112343233       1         Operario Técnico p/ Mantenimiento Z/ Morón
         4509  1112299671       1                              Operario de Producción
         4677  1112355348       1   Operarios de Carga y Descarga  - Zona San Martin
         4812  1112357810       1  Chóferes instaladores - Internet Banda Ancha F...
         5351  1112365531       1         Operarias/or producción  - Zona San Martín

                                                descripcion        nombre_zona  \
         1910  <p>Seleccionaremos para empresa de Caucho, ubi...  Gran Buenos Aires
         4509  <p>Para una importante empresa de Manufactura ...  Gran Buenos Aires
         4677  <p><strong>Adecco Outsourcing</strong> es la l...  Gran Buenos Aires
         4812  <p>Formar parte de la planta de Técnicos e Ins...  Gran Buenos Aires
         5351  <p><strong>Adecco Outsourcing</strong> es la l...  Gran Buenos Aires

              ciudad mapacalle tipo_de_trabajo         nivel_laboral    nombre_area  \
         1910    NaN       NaN       Full-time  Senior / Semi-Senior  Mantenimiento
         4509    NaN       NaN       Full-time                 Otro     Producción
         4677    NaN       NaN       Full-time               Junior     Producción
         4812    NaN       NaN       Full-time               Junior       Internet
         5351    NaN       NaN       Full-time               Junior     Producción

                             denominacion_empresa
         1910  EXTRAMEN SERVICIOS EVENTUALES S.R.L
         4509                        EBM Consultores
         4677           Adecco -Sales & Marketing
         4812                                   FS
         5351           Adecco -Sales & Marketing
```

ES curioso que los anuncios con mayor tasa de conversion buscan todos a operarios/as. el unico anuncio que no tinee esto en el título tiene una palabra similar: instalador. Son tambien todos full-time, aunque con distintos grados de seniority.

5.2 ¿Cómo se relaciona el nivel educativo de los postulantes con los datos que tenemos de los anuncios a los que se postulan?

Vamos a agarrar el set de datos de postulaciones y lo vamos a unir con el tipo de educacion de cada postulante

```
In [19]: postulantes_educacion = postulantes_educacion.loc[:,['idpostulante', 'nombre-estado']]
```

```
In [22]: postulaciones = pd.merge(postulaciones, postulantes_educacion, on='idpostulante', how =
```

Y ahora le vamos a agregar los datos de cada aviso

```
In [25]: avisos_detalles = avisos_detalles.loc[:,['idaviso', 'tipo_de_trabajo', 'nivel_laboral',

In [26]: avisos_detalles.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 13534 entries, 0 to 13533
Data columns (total 5 columns):
idaviso                 13534 non-null int64
tipo_de_trabajo         13534 non-null object
nivel_laboral           13534 non-null object
nombre_area             13534 non-null object
denominacion_empresa    13529 non-null object
dtypes: int64(1), object(4)
memory usage: 528.7+ KB
```

Elimino tildes así despues no tengo que estar luchando con eso

```
In [28]: avisos_detalles['tipo_de_trabajo'] = avisos_detalles['tipo_de_trabajo'].astype('string'
         avisos_detalles['tipo_de_trabajo'] = avisos_detalles['tipo_de_trabajo'].apply(lambda x:

         avisos_detalles['nivel_laboral'] = avisos_detalles['nivel_laboral'].astype('string')
         avisos_detalles['nivel_laboral'] = avisos_detalles['nivel_laboral'].apply(lambda x: eli

         avisos_detalles['nombre_area'] = avisos_detalles['nombre_area'].astype('string')
         avisos_detalles['nombre_area'] = avisos_detalles['nombre_area'].apply(lambda x: elimina

         avisos_detalles['denominacion_empresa'] = avisos_detalles['denominacion_empresa'].astyp
         avisos_detalles['denominacion_empresa'] = avisos_detalles['denominacion_empresa'].apply

In [29]: import unicodedata
         def elimina_tildes(s):
            return ''.join((c for c in unicodedata.normalize('NFD', s) if unicodedata.category(c

         def eliminar_tildes_dict(keys):
             kdict = {}
             for k in keys:
                 kdict[k] = elimina_tildes(k.decode('utf-8'))

             return kdict

In [30]: avisos_detalles['tipo_de_trabajo'] = avisos_detalles['tipo_de_trabajo'].astype('categor
         avisos_detalles['nivel_laboral'] = avisos_detalles['nivel_laboral'].astype('category')
         avisos_detalles['nombre_area'] = avisos_detalles['nombre_area'].astype('category')

In [31]: avisos_detalles.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 13534 entries, 0 to 13533
```

```
Data columns (total 5 columns):
idaviso                 13534 non-null int64
tipo_de_trabajo         13534 non-null category
nivel_laboral           13534 non-null category
nombre_area             13534 non-null category
denominacion_empresa    13534 non-null object
dtypes: category(3), int64(1), object(1)
memory usage: 271.3+ KB
```

```
In [32]: postulaciones = pd.merge(postulaciones, avisos_detalles, on='idaviso', how = 'left')
```

```
In [33]: postulaciones.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 3401623 entries, 0 to 3401622
Data columns (total 8 columns):
idaviso                 int64
idpostulante            object
fechapostulacion        object
nombre-estado           category
tipo_de_trabajo         category
nivel_laboral           category
nombre_area             category
denominacion_empresa    object
dtypes: category(4), int64(1), object(3)
memory usage: 146.0+ MB
```

5.2.1 Comienzo con un heatmap relacionando las categorías nombre-estado y tipo_de_trabajo

```
In [34]: pd.crosstab(index=postulaciones['nombre-estado'],
                     columns=[postulaciones['tipo_de_trabajo']], margins=True)
```

Out[34]:

tipo_de_trabajo	Fines de Semana	Full-time	Part-time	\
nombre-estado				
Otro - Abandonado	4	1980	114	
Otro - En Curso	3	1682	203	
Otro - Graduado	10	9535	998	
Secundario - Abandonado	26	28175	1731	
Secundario - En Curso	64	36388	5209	
Secundario - Graduado	585	743740	111323	
Terciario/Tecnico - Abandonado	23	37598	5843	
Terciario/Tecnico - En Curso	107	124640	26722	
Terciario/Tecnico - Graduado	166	185040	26000	
Universitario - Abandonado	56	138727	22429	
Universitario - En Curso	320	655627	141140	
Universitario - Graduado	357	460347	35103	
Posgrado - Abandonado	0	3762	317	

Posgrado - En Curso	13	21912	1692
Posgrado - Graduado	47	55037	3705
Master - Abandonado	0	2242	70
Master - En Curso	7	19569	894
Master - Graduado	3	26202	1398
Doctorado - Abandonado	0	284	10
Doctorado - En Curso	0	1388	201
Doctorado - Graduado	0	1232	74
All	1791	2555107	385176

tipo_de_trabajo nombre-estado	Pasantia	Por Contrato	Por Horas	\
Otro - Abandonado	1	1	38	
Otro - En Curso	2	3	18	
Otro - Graduado	16	15	86	
Secundario - Abandonado	9	41	387	
Secundario - En Curso	71	37	439	
Secundario - Graduado	976	785	4956	
Terciario/Tecnico - Abandonado	47	62	142	
Terciario/Tecnico - En Curso	502	144	560	
Terciario/Tecnico - Graduado	522	239	774	
Universitario - Abandonado	339	168	385	
Universitario - En Curso	9711	898	1987	
Universitario - Graduado	2706	991	893	
Posgrado - Abandonado	11	13	9	
Posgrado - En Curso	127	58	44	
Posgrado - Graduado	157	155	153	
Master - Abandonado	5	7	4	
Master - En Curso	78	50	29	
Master - Graduado	61	81	59	
Doctorado - Abandonado	0	2	1	
Doctorado - En Curso	4	7	5	
Doctorado - Graduado	3	1	0	
All	15348	3758	10969	

tipo_de_trabajo nombre-estado	Primer empleo	Teletrabajo	Temporario	\
Otro - Abandonado	0	0	8	
Otro - En Curso	0	2	10	
Otro - Graduado	0	13	47	
Secundario - Abandonado	2	18	105	
Secundario - En Curso	2	45	128	
Secundario - Graduado	21	861	3248	
Terciario/Tecnico - Abandonado	0	55	112	
Terciario/Tecnico - En Curso	6	194	433	
Terciario/Tecnico - Graduado	10	261	722	
Universitario - Abandonado	4	173	419	
Universitario - En Curso	49	1082	2329	

```
Universitario - Graduado                  17          712        1223
Posgrado - Abandonado                      0            8           8
Posgrado - En Curso                        0           31          51
Posgrado - Graduado                        5          124         141
Master - Abandonado                        0           13           4
Master - En Curso                          1           50          40
Master - Graduado                          1           76          63
Doctorado - Abandonado                     0            1           1
Doctorado - En Curso                       0            0           2
Doctorado - Graduado                       0            3           7
All                                      118         3722        9101
```

```
tipo_de_trabajo                    All
nombre-estado
Otro - Abandonado                 2146
Otro - En Curso                   1923
Otro - Graduado                  10720
Secundario - Abandonado          30494
Secundario - En Curso            42383
Secundario - Graduado           866495
Terciario/Tecnico - Abandonado   43882
Terciario/Tecnico - En Curso    153308
Terciario/Tecnico - Graduado    213734
Universitario - Abandonado      162700
Universitario - En Curso        813143
Universitario - Graduado        502349
Posgrado - Abandonado             4128
Posgrado - En Curso              23928
Posgrado - Graduado              59524
Master - Abandonado               2345
Master - En Curso                20718
Master - Graduado                27944
Doctorado - Abandonado             299
Doctorado - En Curso              1607
Doctorado - Graduado              1320
All                            2985090
```

In [37]:
```
ind = postulaciones['nombre-estado']
cols = [postulaciones['tipo_de_trabajo']]

table = pd.crosstab(index= ind,columns= cols, margins=True, normalize = 'columns')
```

In [38]:
```
ax = plt.axes()
ind = postulaciones['nombre-estado']
data = pd.crosstab(index= ind,
            columns=[postulaciones['tipo_de_trabajo']], margins=True, normalize = 'colu
sns.heatmap(data, cmap = 'Reds')
ax.set_title('Relacion entre la educacion de los postulantes \n y el tipo de trabajo al
```

```
        ax.set_ylabel('Educacion de los postulantes')
        ax.set_xlabel('Modalidad de trabajo')
```

```
Out[38]: <matplotlib.text.Text at 0x7fea3d5ad990>
```

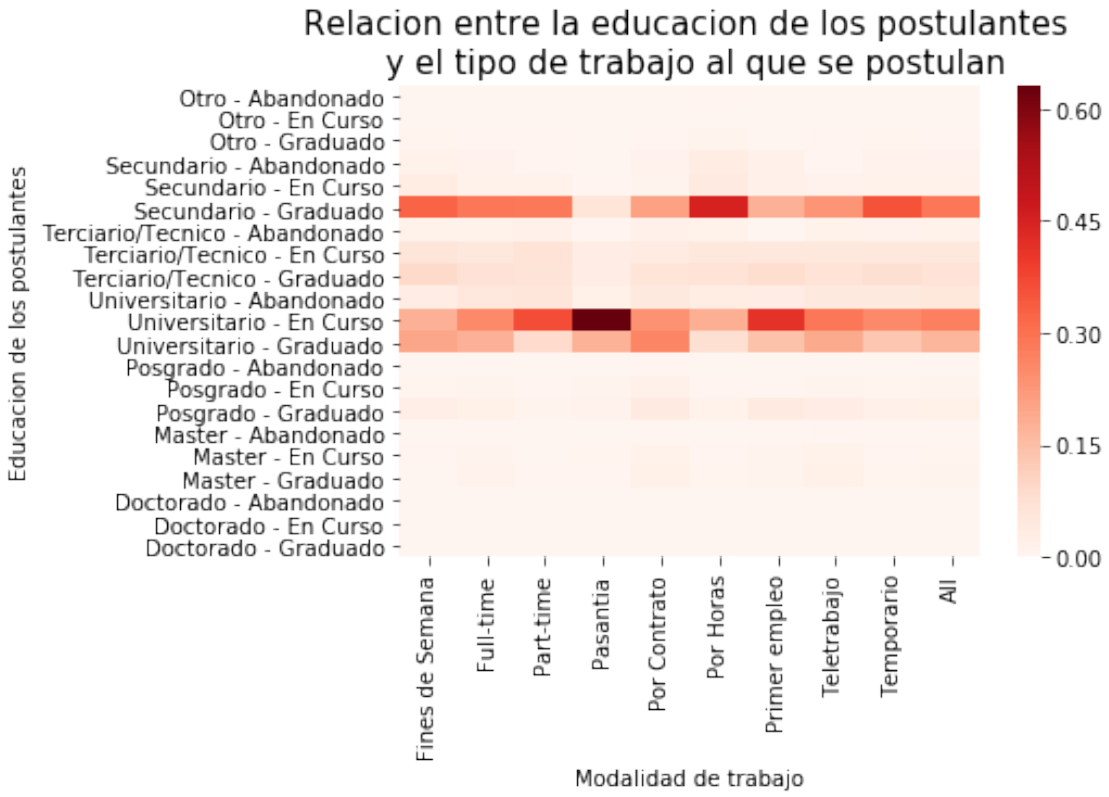

La vizualización no es muy clara, pero si se nota la innegable relación entre las pasantías y primer empleo y los postulantes con nivel universitario en curso. Sin embargo, al haber pocos de algunos niveles de estudio en comparacion con otros se hace dificil la lectura del heatmap

```
In [39]: ax = plt.axes()
         sns.heatmap( table.loc[[#'Otro - Abandonado',
          #'Otro - En Curso',
          #'Otro - Graduado',
         # 'Terciario/Tecnico - Abandonado',
          #'Terciario/Tecnico - En Curso',
          #'Terciario/Tecnico - Graduado',
          'Posgrado - Abandonado',
          'Posgrado - En Curso',
          'Posgrado - Graduado',
          'Master - Abandonado',
          'Master - En Curso',
          'Master - Graduado',
         'Doctorado - Abandonado',
```

```
 'Doctorado - En Curso',
 'Doctorado - Graduado'],:], cmap = 'Reds')
ax.set_title('Relacion entre la educacion post-universitaria \n y el tipo de trabajo al
ax.set_ylabel('Educacion de los postulantes')
ax.set_xlabel('Modalidad de trabajo')
```

Out[39]: <matplotlib.text.Text at 0x7fea3da5e550>

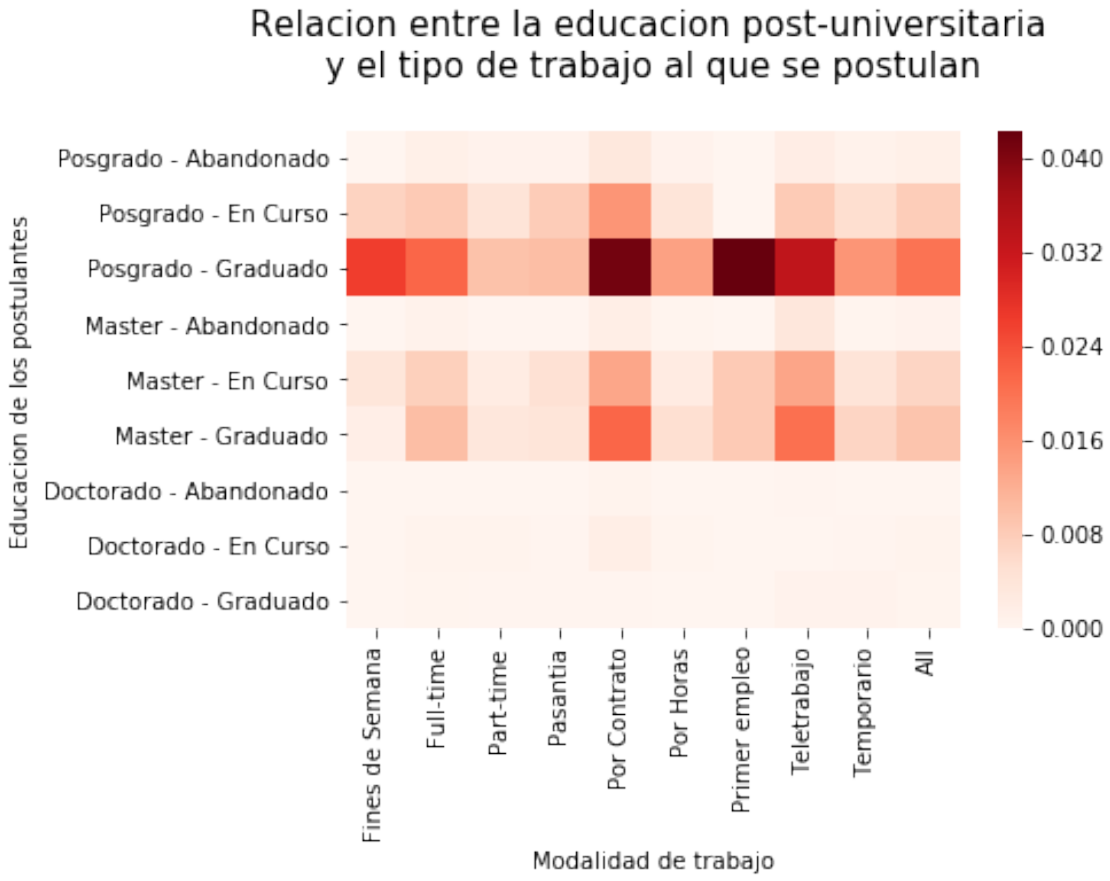

In [40]:
```
ax = plt.axes()
sns.heatmap( table.loc[[
 'Universitario - Abandonado',
 'Universitario - En Curso',
 'Universitario - Graduado','Secundario - Abandonado',
 'Secundario - En Curso',
 'Secundario - Graduado'],:], cmap = 'Reds')
ax.set_title('Relacion de la educacion Secunadaria y universitarya \n con el tipo de tr
ax.set_ylabel('Educacion de los postulantes')
ax.set_xlabel('Modalidad de trabajo')
```

Out[40]: <matplotlib.text.Text at 0x7fea3d5bdf90>

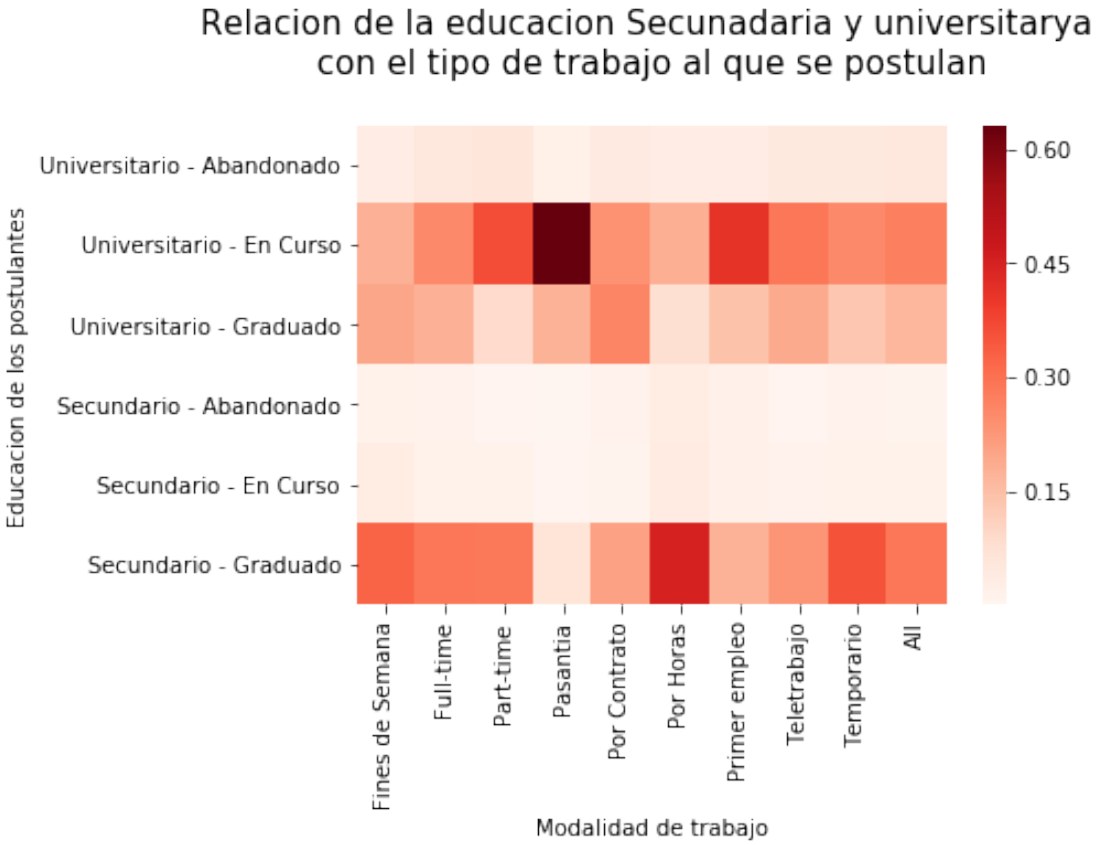


```
In [46]: ax = plt.axes()
         sns.heatmap(table.loc[[
          'Universitario - Abandonado',
          'Universitario - En Curso',
          'Universitario - Graduado','Secundario - Abandonado',
          'Secundario - En Curso',
          'Secundario - Graduado'],['Full-time']],cmap = 'Reds')
         ax.set_title('Relacion entre el trabajo Full-time \n y la educacion secundaria y univer
         ax.set_xlabel('Educacion de los postulantes')
         ax.set_ylabel('Modalidad de trabajo')

Out[46]: <matplotlib.text.Text at 0x7fea3d0f9710>
```

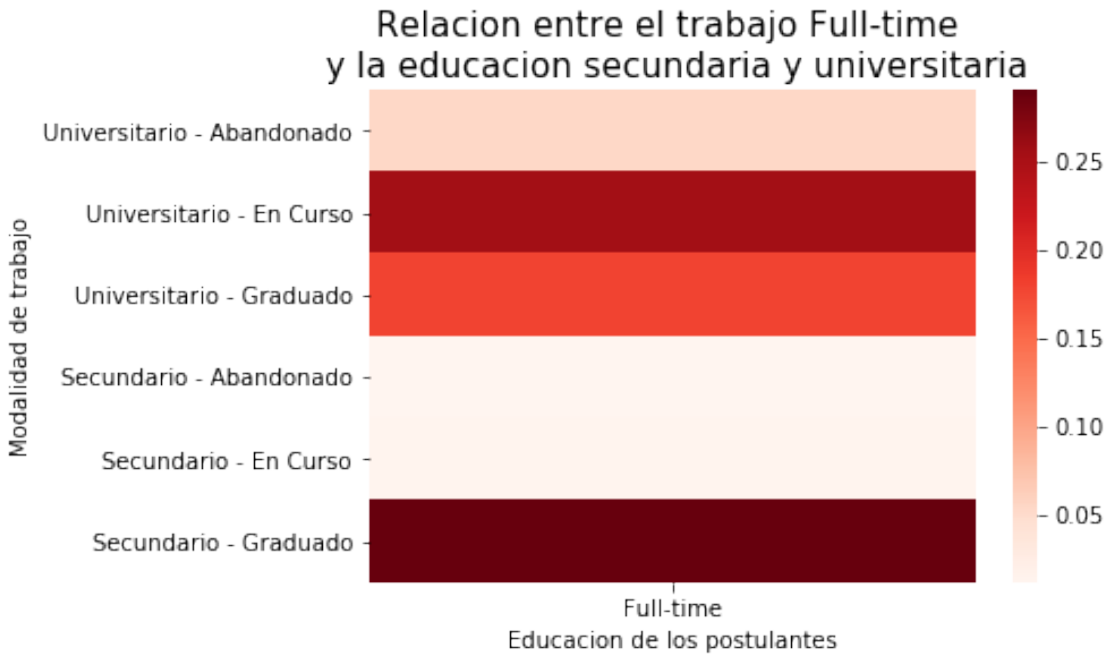


```
In [47]: ax = plt.axes()
         sns.heatmap(table.loc[[
          'Universitario - Abandonado',
          'Universitario - En Curso',
          'Universitario - Graduado','Secundario - Abandonado',
          'Secundario - En Curso',
          'Secundario - Graduado'],['Part-time']],cmap = 'Reds')
         ax.set_title('Relacion entre el trabajo Part-time \n y la educacion secundaria y univer
         ax.set_xlabel('Educacion de los postulantes')
         ax.set_ylabel('Modalidad de trabajo')

Out[47]: <matplotlib.text.Text at 0x7fea3cfa86d0>
```

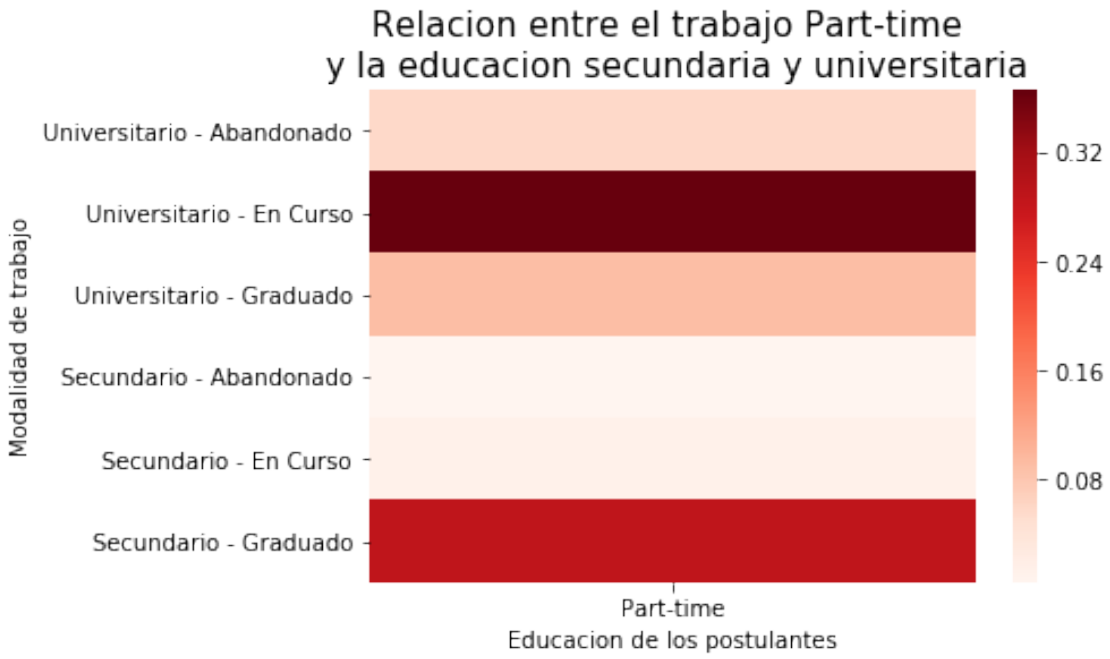

5.3 Relacionamos ahora las categorías nombre-estado y nivel laboral

```
In [48]: ind = postulaciones['nombre-estado']
         cols = [postulaciones['nivel_laboral']]

         table = pd.crosstab(index= ind,columns= cols, margins=True, normalize = 'index')

In [49]: pd.crosstab(index= ind,columns= cols, margins=True)

Out[49]: nivel_laboral                 Gerencia / Alta Gerencia / Direccion  \
         nombre-estado
         Otro - Abandonado                                              7
         Otro - En Curso                                                2
         Otro - Graduado                                               33
         Secundario - Abandonado                                       47
         Secundario - En Curso                                         88
         Secundario - Graduado                                       2556
         Terciario/Tecnico - Abandonado                               286
         Terciario/Tecnico - En Curso                                 518
         Terciario/Tecnico - Graduado                                1336
         Universitario - Abandonado                                  1506
         Universitario - En Curso                                    3785
         Universitario - Graduado                                    7867
         Posgrado - Abandonado                                         84
         Posgrado - En Curso                                          464
         Posgrado - Graduado                                         2161
```

Master - Abandonado	130
Master - En Curso	736
Master - Graduado	1622
Doctorado - Abandonado	8
Doctorado - En Curso	43
Doctorado - Graduado	49
All	23328

nivel_laboral	Jefe / Supervisor / Responsable	Junior
nombre-estado		
Otro - Abandonado	15	399
Otro - En Curso	20	371
Otro - Graduado	158	2020
Secundario - Abandonado	393	5543
Secundario - En Curso	478	8813
Secundario - Graduado	12971	179511
Terciario/Tecnico - Abandonado	1076	9223
Terciario/Tecnico - En Curso	2336	37361
Terciario/Tecnico - Graduado	5485	45759
Universitario - Abandonado	4825	34949
Universitario - En Curso	15076	222652
Universitario - Graduado	28595	103847
Posgrado - Abandonado	271	738
Posgrado - En Curso	1507	4658
Posgrado - Graduado	4799	9624
Master - Abandonado	249	302
Master - En Curso	1705	3493
Master - Graduado	2619	3859
Doctorado - Abandonado	23	39
Doctorado - En Curso	119	309
Doctorado - Graduado	133	184
All	82853	673654

nivel_laboral	Otro	Senior / Semi-Senior	All
nombre-estado			
Otro - Abandonado	305	1420	2146
Otro - En Curso	225	1305	1923
Otro - Graduado	1315	7194	10720
Secundario - Abandonado	4140	20371	30494
Secundario - En Curso	5216	27788	42383
Secundario - Graduado	94924	576533	866495
Terciario/Tecnico - Abandonado	4059	29238	43882
Terciario/Tecnico - En Curso	13897	99196	153308
Terciario/Tecnico - Graduado	17916	143238	213734
Universitario - Abandonado	12642	108778	162700
Universitario - En Curso	61426	510204	813143
Universitario - Graduado	25120	336920	502349
Posgrado - Abandonado	230	2805	4128

```
Posgrado - En Curso                1189                16110    23928
Posgrado - Graduado                2906                40034    59524
Master - Abandonado                  74                 1590     2345
Master - En Curso                   749                14035    20718
Master - Graduado                  1229                18615    27944
Doctorado - Abandonado                5                  224      299
Doctorado - En Curso                 99                 1037     1607
Doctorado - Graduado                 56                  898     1320
All                              247722              1957533  2985090
```

```
In [50]: fig, ax = plt.subplots(figsize = (20,10))
         sns.heatmap(table ,cmap = 'Blues')
         ax.set_title('Relacion entre la educacion de los postulantes \n y el nivel laboral requ
         ax.set_ylabel('Educacion de los postulantes', size = 15)
         ax.set_xlabel('Nivel Laboral', size= 15)
```

```
Out[50]: <matplotlib.text.Text at 0x7fea3c115690>
```

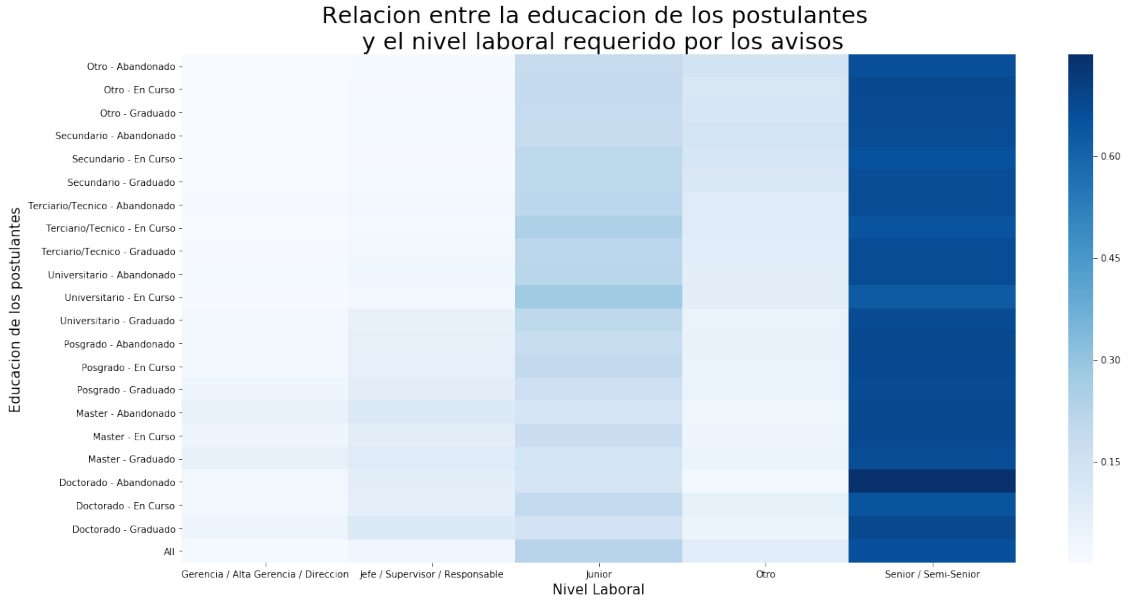

5.4 Relacionamos ahora las categorías nombre-estado y el area

```
In [51]: postulaciones['nombre_area'].value_counts().head(10).index
```

```
Out[51]: CategoricalIndex([u'Ventas', u'Administracion', u'Produccion', u'Comercial',
                           u'Atencion al Cliente', u'Recepcionista', u'Call Center',
                           u'Telemarketing', u'Tesoreria', u'Mantenimiento y Limpieza'],
                          categories=[u'Abastecimiento', u'Administracion', u'Administracion de
```

```
In [57]: ind = postulaciones['nombre-estado']
         cols = postulaciones['nombre_area']
         table = pd.crosstab(index= ind,columns= [cols],
                             margins=True, normalize = 'index')

In [58]: pd.crosstab(index= ind,columns= cols, margins=True)
```

Out[58]:

nombre_area	Abastecimiento	Administracion	\
nombre-estado			
Otro - Abandonado	7	53	
Otro - En Curso	7	95	
Otro - Graduado	35	434	
Secundario - Abandonado	179	573	
Secundario - En Curso	296	986	
Secundario - Graduado	4819	49575	
Terciario/Tecnico - Abandonado	177	4443	
Terciario/Tecnico - En Curso	506	16030	
Terciario/Tecnico - Graduado	700	22100	
Universitario - Abandonado	485	19562	
Universitario - En Curso	2027	108209	
Universitario - Graduado	1099	53586	
Posgrado - Abandonado	9	450	
Posgrado - En Curso	66	2103	
Posgrado - Graduado	156	4965	
Master - Abandonado	14	229	
Master - En Curso	58	1619	
Master - Graduado	82	1931	
Doctorado - Abandonado	1	10	
Doctorado - En Curso	2	194	
Doctorado - Graduado	3	84	
All	10728	287231	

nombre_area	Administracion de Base de Datos	\
nombre-estado		
Otro - Abandonado	0	
Otro - En Curso	0	
Otro - Graduado	0	
Secundario - Abandonado	0	
Secundario - En Curso	0	
Secundario - Graduado	75	
Terciario/Tecnico - Abandonado	6	
Terciario/Tecnico - En Curso	33	
Terciario/Tecnico - Graduado	24	
Universitario - Abandonado	20	
Universitario - En Curso	174	
Universitario - Graduado	137	
Posgrado - Abandonado	0	
Posgrado - En Curso	16	

```
Posgrado - Graduado                                  11
Master - Abandonado                                   1
Master - En Curso                                    10
Master - Graduado                                     8
Doctorado - Abandonado                                0
Doctorado - En Curso                                  1
Doctorado - Graduado                                  1
All                                                 517

nombre_area                    Administracion de Personal  \
nombre-estado
Otro - Abandonado                                    51
Otro - En Curso                                      32
Otro - Graduado                                     146
Secundario - Abandonado                             438
Secundario - En Curso                               607
Secundario - Graduado                              7266
Terciario/Tecnico - Abandonado                      357
Terciario/Tecnico - En Curso                       1632
Terciario/Tecnico - Graduado                       2549
Universitario - Abandonado                         1572
Universitario - En Curso                          11490
Universitario - Graduado                           7821
Posgrado - Abandonado                                29
Posgrado - En Curso                                 367
Posgrado - Graduado                                 792
Master - Abandonado                                  22
Master - En Curso                                   236
Master - Graduado                                   352
Doctorado - Abandonado                                0
Doctorado - En Curso                                 12
Doctorado - Graduado                                 27
All                                                35798

nombre_area                    Administracion de Seguros  \
nombre-estado
Otro - Abandonado                                     0
Otro - En Curso                                       2
Otro - Graduado                                      13
Secundario - Abandonado                              10
Secundario - En Curso                                14
Secundario - Graduado                               730
Terciario/Tecnico - Abandonado                       83
Terciario/Tecnico - En Curso                        255
Terciario/Tecnico - Graduado                        349
Universitario - Abandonado                          299
Universitario - En Curso                           1464
Universitario - Graduado                            990
```

```
Posgrado - Abandonado                                6
Posgrado - En Curso                                 42
Posgrado - Graduado                                111
Master - Abandonado                                  3
Master - En Curso                                   37
Master - Graduado                                   30
Doctorado - Abandonado                               0
Doctorado - En Curso                                 2
Doctorado - Graduado                                 2
All                                               4442

nombre_area                    Almacen / Deposito / Expedicion  \
nombre-estado
Otro - Abandonado                                          72
Otro - En Curso                                            42
Otro - Graduado                                           263
Secundario - Abandonado                                  1424
Secundario - En Curso                                    1524
Secundario - Graduado                                   27435
Terciario/Tecnico - Abandonado                            905
Terciario/Tecnico - En Curso                             2258
Terciario/Tecnico - Graduado                             3394
Universitario - Abandonado                               2167
Universitario - En Curso                                 7150
Universitario - Graduado                                 2757
Posgrado - Abandonado                                      38
Posgrado - En Curso                                       149
Posgrado - Graduado                                       507
Master - Abandonado                                        19
Master - En Curso                                          89
Master - Graduado                                         227
Doctorado - Abandonado                                      1
Doctorado - En Curso                                        8
Doctorado - Graduado                                        4
All                                                     50433

nombre_area                    Analisis Funcional  Analisis de Riesgos  \
nombre-estado
Otro - Abandonado                               0                    0
Otro - En Curso                                 3                    1
Otro - Graduado                                 8                    5
Secundario - Abandonado                         5                    4
Secundario - En Curso                          17                    9
Secundario - Graduado                         375                  296
Terciario/Tecnico - Abandonado                 31                   35
Terciario/Tecnico - En Curso                  293                  158
Terciario/Tecnico - Graduado                  390                  180
Universitario - Abandonado                    316                  246
```

```
Universitario - En Curso                    1606                2344
Universitario - Graduado                    2004                2395
Posgrado - Abandonado                         24                  22
Posgrado - En Curso                           92                  93
Posgrado - Graduado                          249                 242
Master - Abandonado                            9                  10
Master - En Curso                            111                 208
Master - Graduado                            110                 175
Doctorado - Abandonado                         6                   0
Doctorado - En Curso                           1                   6
Doctorado - Graduado                           6                  14
All                                         5656                6443

nombre_area                  Apoderado Aduanal  Arquitectura   ...     \
nombre-estado                                                  ...
Otro - Abandonado                            0             0   ...
Otro - En Curso                              0             5   ...
Otro - Graduado                              1             3   ...
Secundario - Abandonado                      0             6   ...
Secundario - En Curso                        5            18   ...
Secundario - Graduado                       59           357   ...
Terciario/Tecnico - Abandonado               2            48   ...
Terciario/Tecnico - En Curso                34            89   ...
Terciario/Tecnico - Graduado                74           184   ...
Universitario - Abandonado                  19           135   ...
Universitario - En Curso                   156          1621   ...
Universitario - Graduado                    99          3649   ...
Posgrado - Abandonado                        0            20   ...
Posgrado - En Curso                          6           204   ...
Posgrado - Graduado                          7           343   ...
Master - Abandonado                          1            24   ...
Master - En Curso                            3           147   ...
Master - Graduado                            2           139   ...
Doctorado - Abandonado                       0             0   ...
Doctorado - En Curso                         0            16   ...
Doctorado - Graduado                         0             4   ...
All                                        468          7012   ...

nombre_area                  Topografia  Trabajo Social  Transporte  \
nombre-estado
Otro - Abandonado                     0               0          83
Otro - En Curso                       0               0          22
Otro - Graduado                       0               0         205
Secundario - Abandonado               0               1         981
Secundario - En Curso                 0               2         597
Secundario - Graduado                 0              30        9539
Terciario/Tecnico - Abandonado        0               3         320
Terciario/Tecnico - En Curso          0               5         630
```

Terciario/Tecnico - Graduado	0	4	1037
Universitario - Abandonado	0	4	618
Universitario - En Curso	0	23	1809
Universitario - Graduado	0	15	731
Posgrado - Abandonado	0	0	16
Posgrado - En Curso	0	2	47
Posgrado - Graduado	0	0	140
Master - Abandonado	0	0	1
Master - En Curso	1	0	58
Master - Graduado	0	0	72
Doctorado - Abandonado	0	0	0
Doctorado - En Curso	0	0	0
Doctorado - Graduado	0	0	5
All	1	89	16911

nombre_area nombre-estado	Turismo	Urbanismo	Venta de Seguros	Ventas	\
Otro - Abandonado	3	0	1	141	
Otro - En Curso	0	0	0	237	
Otro - Graduado	9	0	15	1109	
Secundario - Abandonado	12	0	4	2698	
Secundario - En Curso	33	0	15	6521	
Secundario - Graduado	618	2	728	144349	
Terciario/Tecnico - Abandonado	64	0	63	7992	
Terciario/Tecnico - En Curso	253	0	195	25095	
Terciario/Tecnico - Graduado	424	2	274	30846	
Universitario - Abandonado	233	0	284	26545	
Universitario - En Curso	1256	0	1329	101183	
Universitario - Graduado	745	4	651	38199	
Posgrado - Abandonado	1	0	2	355	
Posgrado - En Curso	29	1	26	1596	
Posgrado - Graduado	46	1	64	4658	
Master - Abandonado	4	0	1	155	
Master - En Curso	28	1	24	1060	
Master - Graduado	46	0	17	2251	
Doctorado - Abandonado	1	0	0	14	
Doctorado - En Curso	5	0	1	110	
Doctorado - Graduado	1	0	1	89	
All	3811	11	3695	395203	

nombre_area nombre-estado	Ventas Internacionales/Exportacion	\
Otro - Abandonado	0	
Otro - En Curso	3	
Otro - Graduado	4	
Secundario - Abandonado	17	
Secundario - En Curso	26	
Secundario - Graduado	605	

```
Terciario/Tecnico - Abandonado                    46
Terciario/Tecnico - En Curso                     388
Terciario/Tecnico - Graduado                     631
Universitario - Abandonado                       284
Universitario - En Curso                        2295
Universitario - Graduado                        1989
Posgrado - Abandonado                              5
Posgrado - En Curso                               92
Posgrado - Graduado                              244
Master - Abandonado                                6
Master - En Curso                                108
Master - Graduado                                 97
Doctorado - Abandonado                             0
Doctorado - En Curso                               2
Doctorado - Graduado                               1
All                                             6843

nombre_area                     Veterinaria      All
nombre-estado
Otro - Abandonado                         0     2146
Otro - En Curso                           0     1923
Otro - Graduado                           2    10720
Secundario - Abandonado                   0    30494
Secundario - En Curso                     2    42383
Secundario - Graduado                    10   866495
Terciario/Tecnico - Abandonado            1    43882
Terciario/Tecnico - En Curso              2   153308
Terciario/Tecnico - Graduado             18   213734
Universitario - Abandonado               13   162700
Universitario - En Curso                  9   813143
Universitario - Graduado                 37   502349
Posgrado - Abandonado                     0     4128
Posgrado - En Curso                       4    23928
Posgrado - Graduado                       2    59524
Master - Abandonado                       2     2345
Master - En Curso                         1    20718
Master - Graduado                         0    27944
Doctorado - Abandonado                    0      299
Doctorado - En Curso                      0     1607
Doctorado - Graduado                      0     1320
All                                     103  2985090

[22 rows x 163 columns]
```

In [59]:
```
fig, ax = plt.subplots(figsize = (15,10))
sns.heatmap(table.loc[:,[u'Ventas', u'Administracion', u'Produccion', u'Comercial',
                         u'Atencion al Cliente', u'Recepcionista', u'Call Center',
                         u'Telemarketing', u'Tesoreria', u'Mantenimiento y Limpieza']],cmap =
```

```
        ax.set_title('Relacion entre el trabajo Part-time \n y la educacion secundaria y univer
        ax.set_xlabel('Educacion de los postulantes', size = 15)
        ax.set_ylabel('Modalidad de trabajo', size = 15)
```

Out[59]: <matplotlib.text.Text at 0x7fea3d29bc50>

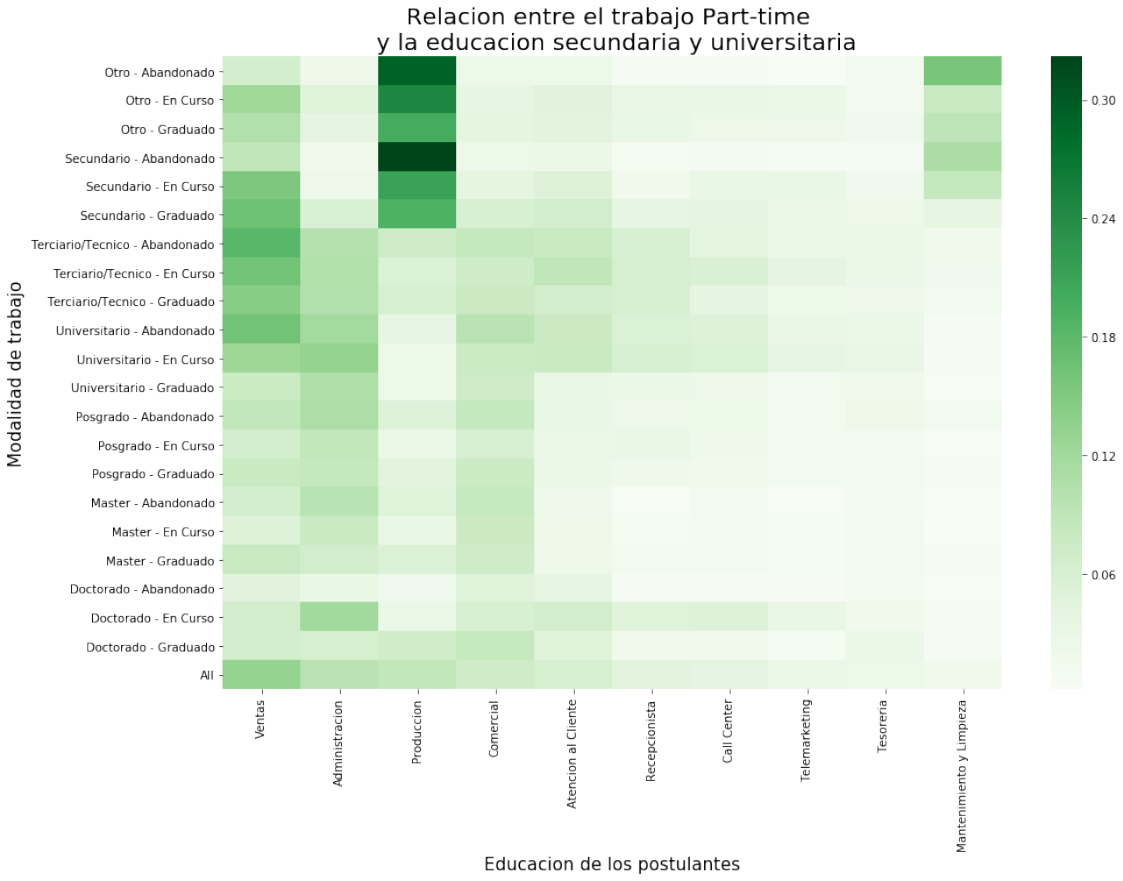

5.5 ¿Como se relaciona la cantidad de vistas por area con el sexo de los postulentes?

```
In [5]: avisos_detalles = pd.read_csv('/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_
        vistas=pd.read_csv("/home/luupesado/7506_Datos/2018/datos_navent_fiuba/fiuba_3_vistas.cs
        postulantes_genero_edad = pd.read_csv("/home/luupesado/7506_Datos/2018/datos_navent_fiub
```

```
In [6]: avisos_con_area=avisos_detalles[["idaviso","nombre_area"]]
```

```
In [7]: visitas_con_datos = vistas.join(postulantes_genero_edad.set_index('idpostulante'), on='i
        visitas_con_datos = visitas_con_datos.join(avisos_con_area.set_index('idaviso'), on='idA
        visitas_hombre=visitas_con_datos[visitas_con_datos["sexo"]=="MASC"]
        visitas_mujer=visitas_con_datos[visitas_con_datos["sexo"]=="FEM"]
        visitas_nan=visitas_con_datos[visitas_con_datos["sexo"]=="NO_DECLARA"]
```

```
In [10]: visitas_mujer["nombre_area"].value_counts().head(15).plot(kind="barh",rot=0,figsize=(10
         plt.title('Areas de trabajo mas visitada por Mujeres', fontsize=22);
         plt.xlabel('Cantidad de Visitas', fontsize=20);
         plt.ylabel('Area de Trabajos', fontsize=20);
```


```
In [9]: visitas_hombre["nombre_area"].value_counts().head(15).plot(kind="barh",rot=0,figsize=(10
        plt.title('Areas de trabajos mas visitadas por Hombres', fontsize=22);
        plt.xlabel('Cantidad de Visitas', fontsize=20);
        plt.ylabel('Area de Trabajo', fontsize=20);
```

Vemos que el sexo de los postulantes influye mucho en las areas más vistas por ellos. Mientras que el area favorita de los hombre es produccion, para las mujeres se encuentra en el puesto número 9 y con menos de un cuarto de vistas que en su area favorita:ventas.

Ventas es el area mas solictada en general y tanto en hombre como en mujeres se encuentra como favorita.

Otra de las areas favoritas de las mujeres es Recepcion, area que ni siquiera aparece en el top 15 del rubro masculino